

Priorización de blancos terapéuticos sobre una red multicapa

Propagación de evidencia entre organismos y desorfanización de compuestos

Gonzalo Giordano

Corrida del 2026-09-10 10:21

<https://github.com/Gonzalo174/TDR-GW-AI-course>

Resumen

Dado el genoma de un organismo, ordenar sus proteínas por cuán prometedoras son como blanco de un fármaco. La evidencia experimental es escasa y está repartida de forma muy desigual entre organismos, así que la estrategia es propagarla sobre una red de tres capas: compuestos, proteínas y anotaciones funcionales. Evaluada dejando afuera toda la evidencia del organismo que se prioriza, la propagación supera al azar en los 16 organismos, con una mediana de AUC01 de 0.645; los 4 primeros puestos son los 4 protozoos parásitos, y el único parámetro que decide el resultado es la penalización de las categorías grandes. El mismo modelo aplicado a compuestos con un único blanco conocido recupera ese blanco en el 3.4 % de los casos, y la razón está medida: el 69 % no tiene ningún vecino químico con blanco conocido, y cuando la semilla sí comparte una anotación con el blanco la recuperación es del 98.9 %. Todo se corrió sobre una versión codificada de la base, con la procedencia de cada resultado registrada.

1 El problema

Un programa de descubrimiento de fármacos para una enfermedad desatendida empieza por elegir qué proteína atacar, y esa elección se hace con poca evidencia: para la mayoría de los organismos de interés se conocen apenas decenas de proteínas con actividad medida, sobre genomas de miles.

La hipótesis que explota este trabajo es que la evidencia se puede transferir. Dos proteínas que comparten un dominio funcional tienden a comportarse parecido frente a un compuesto, y dos compuestos químicamente similares tienden a actuar sobre las mismas proteínas. Formalizado, eso es una red de tres capas sobre la que se propaga una señal desde las proteínas con evidencia hacia las que no la tienen [2]. El trabajo responde dos preguntas con esa red: *¿qué tan bien prioriza el genoma de un organismo del que no se sabe nada?* (Sección 3) y *¿puede proponer el blanco de un compuesto que no tiene ninguno?* (Sección 4).

2 Datos y método

La base tiene 399 353 proteínas de 16 organismos con evidencia suficiente, 248 545 enlaces de bioactividad positiva y 769 661 afiliaciones a 14 083 dominios InterPro y 76 157 grupos de ortología. La evidencia por organismo va de 19 a 1 985 proteínas con actividad conocida (Figura 1): esa desigualdad es la premisa del método.

La versión publicada en el repositorio está *codificada* —toda columna es un entero y los diccionarios que traducen esos enteros son privados— y *recortada*: se eliminaron las componentes conexas del grafo de similitud química sin ningún compuesto de bioactividad positiva (2 396 103→831 175 compuestos), que por construcción no pueden aportar a una propagación




Figura 1: Evidencia disponible por organismo, en escala logarítmica en los dos ejes.

desde evidencia positiva. Los organismos se identifican por código y por tipo; el nombre no se publica en ninguna parte.

Propagación. Las anotaciones se puntúan por cuánto se enriquecen en proteínas ya conocidas como blanco: un test exacto de Fisher unilateral por categoría, corregido con Benjamini–Hochberg [1]. Esa puntuación pondera la propagación hacia las proteínas sin evidencia, que tiene cuatro parámetros: α (cuánto pesa la puntuación de la categoría), β (cuánto se penaliza a las categorías grandes; $\beta = 0$ es la red G'_r y $\beta > 0$ la G'_{rk}), λ y γ (cómo se combinan las categorías de una proteína).

Métrica. El área parcial bajo la curva ROC restringida a $\text{FPR} \leq 0.10$, corregida por McClish [3] para que el azar valga 0.5 y el clasificador perfecto 1.0 (AUC01). Sólo importa el extremo del ranking: nadie va a ensayar más allá de las primeras decenas de proteínas. La pAUC se integra interpolando el punto exacto ($\text{FPR}_{\max}$, TPR); truncar en el último punto, que es lo directo, subestima el área.

Validación. *Leave-one-species-out*: para evaluar un organismo se retira toda su evidencia de la semilla y se lo prioriza como si no se supiera nada de él. Una prueba dedicada comprueba que ninguna proteína del organismo evaluado sobrevive en la semilla, con su control negativo al lado.

3 Priorización de genoma completo

Para cada organismo se barrieron las 120 combinaciones válidas de los cuatro parámetros. En su óptimo, la priorización alcanza una mediana de AUC01 de 0.645 entre los 16 organismos, con un rango de 0.581 a 0.849, y supera el azar en los 16 (Figura 2, Cuadro 1). El orden no es arbitrario: los 4 primeros puestos son los 4 protozoos parásitos, y los últimos son bacterias y hongos.

La Figura 3 muestra qué significa ese número para el organismo foco del trabajo, un protozoo parásito (sp 26): AUC global de 0.841 y AUC01 de 0.736. La distribución de puntajes explica la forma de la curva: la mayoría de sus 95 proteínas druggables recibe un puntaje en la cola alta, pero 5 no reciben ninguno, porque no comparten anotación con nada que tenga evidencia:




Figura 2: AUC01 en el óptimo de cada organismo, bajo leave-one-species-out. La línea punteada marca el azar.

Cuadro 1: Óptimo por organismo. λ híbrido es el modo que combina las categorías con γ .

especie	grupo	parásito	AUC01	AUC	α	β	λ	γ
sp04	Protozoos	sí	0.849	0.883	0	1	1	0.8
sp15	Protozoos	sí	0.789	0.844	0.3	1.5	híbrido	0.8
sp23	Protozoos	sí	0.743	0.859	0	1.5	0.5	0.8
sp26	Protozoos	sí	0.736	0.841	1.2	1	1	0.8
sp21	Plantas	no	0.683	0.828	0	1	0.5	0.8
sp09	Invertebrados	no	0.664	0.781	0.3	1.5	1	0.8
sp22	Amebozoos	no	0.652	0.871	0	1	1	0.8
sp25	Hongos	sí	0.645	0.868	1.2	1	0.5	0.8
sp28	Plantas	no	0.644	0.843	1.2	1	0.5	0.8
sp17	Invertebrados	no	0.614	0.812	0	1	1	0.8
sp18	Mamíferos	no	0.611	0.818	0.3	1	híbrido	0.8
sp03	Mamíferos	no	0.594	0.769	0	0.5	1	0.8
sp05	Bacterias	sí	0.591	0.878	0.3	0.5	0.5	0.8
sp01	Bacterias	sí	0.588	0.820	1.2	1	1	0.8
sp10	Hongos	no	0.581	0.743	0.9	0	0	0.8
sp00	Bacterias	sí	0.581	0.866	1.2	1	híbrido	0.8

son las que la curva sólo alcanza al final.

Qué decide el resultado. De los cuatro parámetros, sólo β mueve la AUC01 de forma consistente (Figura 4): penalizar a las categorías grandes mejora la priorización, y el óptimo tiene $\beta > 0$ en 15 de los 16 organismos. Contado sobre las diez mejores combinaciones de cada organismo, $\beta = 1$ aparece 2.45 veces más de lo que daría el azar y $\beta = 0$ apenas 0.25; el 94 % de esas combinaciones tiene $\beta > 0$. α , λ y γ casi no cambian la mediana.

Qué tan firme es el óptimo. Un número óptimo sólo significa algo si no es un pico casual. En todos los organismos, las veinte mejores combinaciones quedan a menos del 2.1 % de la AUC01 máxima (Figura 5): el óptimo es una meseta, y la elección de parámetros no es frágil. Además, el perfil de la grilla se parece entre organismos: la correlación de Spearman mediana entre pares es 0.64, y es positiva en el 85 % de los pares. Los parámetros que funcionan en un organismo funcionan en los demás.




Figura 3: Organismo foco en su óptimo. Izquierda: ROC global, con el corte de FPR = 0.1 que define la AUC01. Derecha: puntaje de propagación (NDS) de las proteínas druggables frente al resto.




Figura 4: AUC01 de las 120 combinaciones por organismo, agrupadas por el valor de cada parámetro. El panel de β compara G'_r ($\beta = 0$) con G'_{rk} .




Figura 5: Caída relativa de la AUC01 entre el óptimo y la K -ésima mejor combinación, por organismo.

4 Desorfanización de compuestos

La segunda pregunta invierte la dirección: dado un compuesto sin blanco conocido, proponer uno. Para poder medir el acierto se usan *pseudohuérfanas*: compuestos con exactamente un blanco conocido en un organismo (60 253 en la base), a los que se les borra toda su bioactividad. La semilla se arma entonces desde su vecindario químico —los compuestos similares que sí

tienen blanco—, se propaga con los parámetros óptimos del organismo, y se mide la posición relativa del blanco verdadero entre las proteínas del organismo (*frank*; se lo cuenta recuperado si $\text{frank} < 0.1$). Se evaluaron 7782 pseudohuérfanas, hasta mil por organismo.

El resultado global es bajo, y la causa está medida. El blanco se recupera en el 3.4 % de los casos. La Figura 6 muestra por qué: la recuperación la decide la *clase de semilla*, no el modelo. El 69 % de las pseudohuérfanas no tiene ningún vecino químico con blanco conocido (semilla nula), y no hay propagación posible. De las que tienen semilla, 2154 la tienen *no informativa*: ninguna de sus proteínas comparte una anotación con el blanco verdadero, y la recuperación es del 0.0 %. Las 270 restantes, con al menos una anotación en común, se recuperan en el 98.9 %.




Figura 6: Izquierda: recuperación por clase de semilla. Derecha: composición de la semilla por organismo; la fracción informativa (verde) es el techo del método.

La fracción informativa es entonces un techo: ninguna reponderación de la red puede superarla. Por organismo va del 0.7 % al 16 %. Por la misma razón, los compuestos cuyo cluster químico tiene enlaces a bioactividad positiva y blancos en más de un organismo (grupo 3) se recuperan más que los que no tienen ninguna de las dos cosas (grupo 0): 6.1 % contra 1.9 %. Se probaron tres palancas para ampliar la semilla sobre 500 pseudohuérfanas sin semilla informativa —subir el umbral de similitud, agregar KEGG como tercera fuente de anotaciones y usar la actividad fenotípica como respaldo— y rescataron 0. Las dos primeras no podían hacerlo en esta base: la capa química guardada sólo permite subir el umbral, que quita vecinos, y el mapeo a KEGG no está disponible.

Cuando hay semilla informativa. El 98.9 % dice poco: con unas doce mil proteínas por organismo, $\text{frank} < 0.1$ es quedar entre las primeras ~ 1309 , y sólo 3 de las 270 quedan afuera. La Figura 7 mira la posición absoluta. El blanco verdadero queda primero en el 26 % de los casos, entre los diez primeros en el 62 % y entre los cien primeros en el 87 %; el azar pondría en el top-10 al 0.13 %. Detrás de ese promedio hay dos poblaciones. En las 170 de inferencia directa —el blanco verdadero ya está en la semilla, lo trae un vecino químico— la posición mediana es 2 y el 77 % cae en el top-10; en las 100 indirectas, donde sólo se llega por anotaciones compartidas, la mediana es 29.5 y el top-10 baja al 36 %. Las semillas grandes diluyen la señal: el tamaño de la semilla y la posición del blanco se correlacionan ($\rho = 0.42$), y la correlación es positiva dentro de 8 de los 8 organismos con al menos quince casos, así que no es un efecto de mezclar organismos. Una advertencia de lectura: en el 37 % de los casos el blanco comparte puntaje con otras proteínas y su posición es un promedio de empate.

Hasta dónde confiar en el ranking. Sobre el ranking global (las 399353 proteínas de la red), la curva de recuperación acumulada tiene una pendiente alta en las primeras posiciones que cae al ruido de fondo en $r_G^* = 74$ (Figura 8): una propuesta más abajo que eso no se distingue del azar. Ese corte separa dos mecanismos. En la inferencia *directa* el blanco verdadero está entre las semillas (lo trae un vecino químico); en la *indirecta* sólo se llega por la capa de anotaciones. La directa es el 7 % de los casos con ranking y pone el blanco en la posición global mediana




Figura 7: Las 270 pseudohuérfanas con semilla informativa. (a) Fracción con el blanco entre las k primeras proteínas de su organismo, frente al azar; la línea punteada es el corte $\text{frank} = 0.1$. (b) frank en escala logarítmica. (c) Tamaño de la semilla contra posición del blanco. (d) Posición por organismo; la barra es la mediana.

46 (posición 2 dentro del organismo); la indirecta, el 93%, lo pone en la 186 011. El trabajo original reporta una partición 68 % / 32 % [2]: aquí casi toda la recuperación útil viene de vecinos químicos.




Figura 8: Arriba: compuestos cuyo blanco verdadero cae antes de la posición l del ranking global. Abajo: su derivada, suavizada, y el umbral $\lambda_{\infty} + 3\sigma$ que define r_G^* .

Aplicación al organismo foco. De 174 compuestos con actividad fenotípica contra sp 26, 3

no tienen blanco proteico conocido y los 3 tienen vecinos químicos con blanco. Ninguno recibe una propuesta por encima de r_G^* (0 sugerencias): con la base recortada el embudo es demasiado angosto para producir candidatos, y el método lo dice en vez de forzar una respuesta.

5 Contraste con la versión anterior (v4)

Este repositorio es un port del análisis v4 a la base codificada y recortada. Para saber si el port es fiel, las mismas tablas se calcularon antes de los dos cambios y quedaron versionadas como oráculo. El criterio es uno solo: *si el análisis toca la capa química, el recorte lo mueve; si no la toca, no lo mueve*. De 353 columnas comparadas hay 0 discrepancias (Figura 9):

- **Priorización**, sin capa química: las 149 columnas son idénticas (149), y los óptimos coinciden con los de un control independiente en 16 de 16 organismos, con diferencia máxima de AUC01 de 0.
- **Desorfanización**, que arma la semilla desde el vecindario químico: 83 de 177 columnas cambian, todas en la dirección que el recorte predice. El filtro de promiscuidad pasó de descartar 30 compuestos a 7 —la mayoría no sobrevivió al recorte—, así que más compuestos tienen vecinos: la semilla nula baja del 83 al 69 %, la recuperación sube del 2.6 al 3.4 % y r_G^* pasa de 54 a 74. El conjunto evaluado es el mismo (7 782 pseudohuérfanas en los dos lados).
- **Descriptivos de la base**: 14 de 23 columnas cambian, las que miden componentes químicas.




Figura 9: Columnas comparadas contra el oráculo v4, por análisis. Verde: idéntica; ámbar: cambio explicado por el recorte; rojo sería una discrepancia.

El port no fue gratuito. La base codificada guarda como enteros lo que antes era texto, y cuatro filtros heredados comparaban contra el texto: el de bioactividad positiva (`== "positive"`) devolvía cero filas y descartaba en silencio 248 545 enlaces; InterPro y OrthoMCL se codificaron desde cero por separado y sus códigos se pisaban; la pseudo-especie sin organismo nunca se excluía y aportaba el 53 % de las pseudohuérfanas; y las subestructuras crudas no cruzaban contra la base. Ninguno lanza una excepción, y los cuatro los encontraron las pruebas o la comparación con el oráculo. El detalle está en `PROVENANCE.md`.

6 Verificación, reproducibilidad y límites

Pruebas. 53 pruebas que corren en menos de medio minuto: integridad de las tablas, ausencia de fuga en la validación cruzada, las métricas contra valores de referencia, las rutas, el entorno, y que toda figura se dibuje sin tocar la base.

Corrida y figuras separadas, y cuánto cuesta cada una. Cada notebook tiene una celda de corrida que carga la base y escribe tablas en `resultados/`, y una sección de resultados que sólo las lee. Rehacer las tablas desde la base lleva unos 45 minutos con 20 procesos, casi todo en el barrido de parámetros y en la desorfanización. Las tablas están versionadas en el repositorio: con ellas, las 31 figuras —declaradas en `comun/figuras.py` junto con las tablas que leen, que son su procedencia— se reproducen en unos cuarenta segundos sin volver a correr ningún modelo, y `make verificar` comprueba en alrededor de un minuto que cada cifra de este informe coincida con ellas. Qué verifica cada figura está en `FIGURAS.md`.

Procedencia. Cada corrida deja un `meta.json` junto a sus tablas con la fecha, el notebook de origen, los parámetros, la fecha de cada tabla de entrada y las versiones de python (3.12.11) y pandas (3.0.5). Ningún número de este informe está escrito a mano: se leen de las tablas con `informe/numeros.py`. El registro de decisiones, con lo que se descartó en cada bifurcación, está en `PROVENANCE.md`.

Límites. El repositorio no reproduce la base misma, que se deriva de datos que no se publican; ni el filtro de promiscuidad, que lee las relaciones de subestructura crudas y su diccionario (su salida está versionada); ni los nombres legibles de las anotaciones, que exigen un diccionario privado; ni la identidad de los organismos, que es deliberada.

Referencias

- [1] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.
- [2] Ariel J. Berenstein, María Paula Magariños, Ariel Chernomoretz, and Fernán Agüero. A multilayer network approach for guiding drug repositioning in neglected diseases. *PLoS Neglected Tropical Diseases*, 10(1):e0004300, 2016.
- [3] Donna Katzman McClish. Analyzing a portion of the ROC curve. *Medical Decision Making*, 9(3):190–195, 1989.