

Priorización de blancos terapéuticos sobre una red multicapa

Propagación de evidencia entre organismos y desorfanización de compuestos

Gonzalo Giordano

Corrida del 2026-09-24 16:32

<https://github.com/Gonzalo174/TDR-GW-AI-course>

Resumen

Dado el genoma de un organismo, ordenar sus proteínas por cuán prometedoras son como blanco de un fármaco. La evidencia experimental es escasa y está repartida de forma muy desigual entre organismos, así que la estrategia es propagarla sobre una red de tres capas: compuestos, proteínas y anotaciones funcionales. Evaluada dejando afuera toda la evidencia del organismo que se prioriza, la propagación supera al azar en los 16 organismos, con una mediana de AUC01 de 0.645; los 4 primeros puestos son los 4 protozoos parásitos, y el único parámetro que decide el resultado es la penalización de las categorías grandes. El mismo modelo aplicado a compuestos con un único blanco conocido recupera ese blanco en el 17.5 % de los casos, y la razón está medida: el 68 % no tiene ningún vecino químico con blanco conocido, y cuando la semilla sí comparte una anotación con el blanco la recuperación es del 99.6 %. Todo se corrió sobre una versión codificada de la base, con la procedencia de cada resultado registrada.

1 El problema

Un programa de descubrimiento de fármacos para una enfermedad desatendida empieza por elegir qué proteína atacar, y esa elección se hace con poca evidencia: para la mayoría de los organismos de interés se conocen apenas decenas de proteínas con actividad medida, sobre genomas de miles.

La hipótesis que explota este trabajo es que la evidencia se puede transferir. Dos proteínas que comparten un dominio funcional tienden a comportarse parecido frente a un compuesto, y dos compuestos químicamente similares tienden a actuar sobre las mismas proteínas. Formalizado, eso es una red de tres capas sobre la que se propaga una señal desde las proteínas con evidencia hacia las que no la tienen [2]. El trabajo responde dos preguntas con esa red: *¿qué tan bien prioriza el genoma de un organismo del que no se sabe nada?* (Sección 3) y *¿puede proponer el blanco de un compuesto que no tiene ninguno?* (Sección 4).

2 Datos y método

La base tiene 399 353 proteínas de 16 organismos con evidencia suficiente, 248 545 enlaces de bioactividad positiva y 769 661 afiliaciones a 14 083 dominios InterPro y 76 157 grupos de ortología. La evidencia por organismo va de 19 a 1985 proteínas con actividad conocida (Figura 1): esa desigualdad es la premisa del método.

La versión publicada en el repositorio está *codificada* —toda columna es un entero y los diccionarios que traducen esos enteros son privados— y *recortada*: se eliminaron las componentes conexas del grafo de similitud química sin ningún compuesto de bioactividad positiva (2 396 103 → 831 175 compuestos), que por construcción no pueden aportar a una propagación desde evidencia positiva. Los organismos entran al modelo por su código, pero se nombran;

lo que sigue sin publicarse es la identidad de compuestos, proteínas y anotaciones, con una excepción declarada: los 391 dominios de quinasa, que hacen falta para la Sección 3.




Figura 1: Evidencia disponible por organismo, en escala logarítmica en los dos ejes.

Propagación. Las anotaciones se puntúan por cuánto se enriquecen en proteínas ya conocidas como blanco: un test exacto de Fisher unilateral por categoría, corregido con Benjamini–Hochberg [1]. Esa puntuación pondera la propagación hacia las proteínas sin evidencia, que tiene cuatro parámetros: α (cuánto pesa la puntuación de la categoría), β (cuánto se penaliza a las categorías grandes; $\beta = 0$ es la red G'_r y $\beta > 0$ la G'_{rk}), λ y γ (cómo se combinan las categorías de una proteína).

Métrica. El área parcial bajo la curva ROC restringida a $\text{FPR} \leq 0.10$, corregida por McClish [3] para que el azar valga 0.5 y el clasificador perfecto 1.0 (AUC01). Sólo importa el extremo del ranking: nadie va a ensayar más allá de las primeras decenas de proteínas. La pAUC se integra interpolando el punto exacto ($\text{FPR}_{\max}, \text{TPR}$); truncar en el último punto, que es lo directo, subestima el área.

Validación. *Leave-one-species-out*: para evaluar un organismo se retira toda su evidencia de la semilla y se lo prioriza como si no se supiera nada de él. Una prueba dedicada comprueba que ninguna proteína del organismo evaluado sobrevive en la semilla, con su control negativo al lado.

3 Priorización de genoma completo

Para cada organismo se barrieron las 120 combinaciones válidas de los cuatro parámetros. En su óptimo, la priorización alcanza una mediana de AUC01 de 0.645 entre los 16 organismos, con un rango de 0.581 a 0.849, y supera el azar en los 16 (Figura 2, Cuadro 1). El orden no es arbitrario: los 4 primeros puestos son los 4 protozoos parásitos, y los últimos son bacterias y hongos.

La Figura 3 muestra qué significa ese número para el organismo foco del trabajo, *Plasmodium falciparum*: AUC global de 0.841 y AUC01 de 0.736. La distribución de puntajes explica la forma de la curva: la mayoría de sus 95 proteínas druggables recibe un puntaje en la cola alta, pero 5 no reciben ninguno, porque no comparten anotación con nada que tenga evidencia: son las que la curva sólo alcanza al final.




Figura 2: AUC01 en el óptimo de cada organismo, bajo leave-one-species-out. La línea punteada marca el azar.

Cuadro 1: Óptimo por organismo. λ híbrido es el modo que combina las categorías con γ .

especie	grupo	parásito	AUC01	AUC	α	β	λ	γ
<i>T. cruzi</i>	Protozoos	sí	0.849	0.883	0	1	1	0.8
<i>T. brucei</i>	Protozoos	sí	0.789	0.844	0.3	1.5	híbrido	0.8
<i>L. major</i>	Protozoos	sí	0.743	0.859	0	1.5	0.5	0.8
<i>P. falciparum</i>	Protozoos	sí	0.736	0.841	1.2	1	1	0.8
<i>A. thaliana</i>	Plantas	no	0.683	0.828	0	1	0.5	0.8
<i>C. elegans</i>	Invertebrados	no	0.664	0.781	0.3	1.5	1	0.8
<i>D. discoideum</i>	Amebozoos	no	0.652	0.871	0	1	1	0.8
<i>C. albicans</i>	Hongos	sí	0.645	0.868	1.2	1	0.5	0.8
<i>O. sativa</i>	Plantas	no	0.644	0.843	1.2	1	0.5	0.8
<i>D. melanogaster</i>	Invertebrados	no	0.614	0.812	0	1	1	0.8
<i>M. musculus</i>	Mamíferos	no	0.611	0.818	0.3	1	híbrido	0.8
<i>H. sapiens</i>	Mamíferos	no	0.594	0.769	0	0.5	1	0.8
<i>S. aureus</i>	Bacterias	sí	0.591	0.878	0.3	0.5	0.5	0.8
<i>E. coli</i>	Bacterias	sí	0.588	0.820	1.2	1	1	0.8
<i>S. cerevisiae</i>	Hongos	no	0.581	0.743	0.9	0	0	0.8
<i>M. tuberculosis</i>	Bacterias	sí	0.581	0.866	1.2	1	híbrido	0.8

Qué decide el resultado. De los cuatro parámetros, sólo β mueve la AUC01 de forma consistente (Figura 4): penalizar a las categorías grandes mejora la priorización, y el óptimo tiene $\beta > 0$ en 15 de los 16 organismos. Contado sobre las diez mejores combinaciones de cada organismo, $\beta = 1$ aparece 2.45 veces más de lo que daría el azar y $\beta = 0$ apenas 0.25; el 94 % de esas combinaciones tiene $\beta > 0$. α , λ y γ casi no cambian la mediana.

Qué tan firme es el óptimo. Un número óptimo sólo significa algo si no es un pico casual. En todos los organismos, las veinte mejores combinaciones quedan a menos del 2.1 % de la AUC01 máxima (Figura 5): el óptimo es una meseta, y la elección de parámetros no es frágil. Además, el perfil de la grilla se parece entre organismos: la correlación de Spearman mediana entre pares es 0.64, y es positiva en el 85 % de los pares. Los parámetros que funcionan en un organismo funcionan en los demás.

Sobre quién actúa β . Que β ayude no dice a costa de qué. Para aislarlo, el notebook 03 fija el mejor $(\alpha, \lambda, \gamma)$ de cada organismo dentro de $\beta = 1$ y después mueve sólo β a 0: lo único que cambia entre las dos corridas es la penalización. El grupo de prueba son las quinasas, el caso de libro de una categoría grande y promiscua: 391 de los 14083 dominios, pero el 3.4 % de las




Figura 3: Organismo foco en su óptimo. Izquierda: ROC global, con el corte de FPR = 0.1 que define la AUC01. Derecha: puntaje de propagación (NDS) de las proteínas druggables frente al resto.




Figura 4: AUC01 de las 120 combinaciones por organismo, agrupadas por el valor de cada parámetro. El panel de β compara G'_r ($\beta = 0$) con G'_{rk} .




Figura 5: Caída relativa de la AUC01 entre el óptimo y la K -ésima mejor combinación, por organismo.

proteínas de un genoma típico.

Apagar la penalización cuesta AUC01 en 15 de los 16 organismos (mediana 0.057, máximo 0.275; Figura 6), y lo que se pierde se ve en la cabeza del ranking. Con $\beta = 0$, en 8 organismos las primeras cien posiciones se llenan de quinasas: hasta 37 veces más de las que daría el azar, y en varios casos el top-100 es *enteramente* quinasas. Con $\beta = 1$ ese enriquecimiento no pasa de 3.5 en ningún organismo (Figura 7).

El desplazamiento es específico. Al pasar de $\beta = 0$ a $\beta = 1$ las quinasas bajan en 15 de los 16 organismos —mediana 10.3 percentiles— mientras que la mediana del resto del genoma no se mueve de cero en ninguno (Figura 8). β no reordena el ranking entero: saca del tope a las proteínas que estaban ahí por compartir una anotación que comparte medio genoma.




Figura 6: AUC01 con la penalización ($\beta = 1$) y sin ella ($\beta = 0$), a $(\alpha, \lambda, \gamma)$ fijos en el óptimo de cada organismo.




Figura 7: Quinasas en las primeras cien posiciones, contra las que daría un ranking indiferente a serlo. El conteo es el esperado bajo desempate uniforme: con $\beta = 0$ los puntajes se degeneran y el corte cae dentro de un bloque empatado.

4 Desorfanización de compuestos

La segunda pregunta invierte la dirección: dado un compuesto sin blanco conocido, proponer uno. Para poder medir el acierto se usan *pseudohuérfanas*: compuestos con exactamente un




Figura 8: Desplazamiento en percentiles al pasar de $\beta = 0$ a $\beta = 1$, mediana y cuartiles, separando quinasas del resto del genoma. Positivo = la proteína baja en el ranking.

blanco conocido en un organismo (60 253 en la base), a los que se les borra toda su bioactividad. La semilla se arma entonces desde su vecindario químico —los compuestos similares que sí tienen blanco—, se propaga con los parámetros óptimos del organismo, y se mide la posición relativa del blanco verdadero entre las proteínas del organismo (*frank*; se lo cuenta recuperado si $\text{frank} < 0.1$). Se evaluaron 7 782 pseudohuérfanas, hasta mil por organismo.

El resultado global es bajo, y la causa está medida. El blanco se recupera en el 17.5 % de los casos. La Figura 9 muestra por qué: la recuperación la decide la *clase de semilla*, no el modelo. El 68 % de las pseudohuérfanas no tiene ningún vecino químico con blanco conocido (semilla nula), y no hay propagación posible. De las que tienen semilla, 1 144 la tienen *no informativa*: ninguna de sus proteínas comparte una anotación con el blanco verdadero, y la recuperación es del 0.0 %. Las 1 365 restantes, con al menos una anotación en común, se recuperan en el 99.6 %.




Figura 9: Izquierda: recuperación por clase de semilla. Derecha: composición de la semilla por organismo; la fracción informativa (verde) es el techo del método.

La fracción informativa es entonces un techo: ninguna reponderación de la red puede superarla. Por organismo va del 3.9 % al 33 %. Por la misma razón, los compuestos cuyo cluster químico tiene enlaces a bioactividad positiva y blancos en más de un organismo (grupo 3) se recuperan más que los que no tienen ninguna de las dos cosas (grupo 0): 43.8 % contra 0.8 %. Se probaron

tres palancas para ampliar la semilla sobre 500 pseudohuérfanas sin semilla informativa —subir el umbral de similitud, agregar KEGG como tercera fuente de anotaciones y usar la actividad fenotípica como respaldo— y rescataron 0. Las dos primeras no podían hacerlo en esta base: la capa química guardada sólo permite subir el umbral, que quita vecinos, y el mapeo a KEGG no está disponible.

Cuando hay semilla informativa. El 99.6 % dice poco: en la mediana de estos casos, $\text{frank} < 0.1$ es quedar entre las primeras ~ 656 proteínas del organismo, y sólo 6 de las 1365 quedan afuera. La Figura 10 mira la posición absoluta. El blanco verdadero queda primero en el 30 % de los casos, entre los diez primeros en el 72 % y entre los cien primeros en el 93 %; el azar pondría en el top-10 al 0.13 %. Detrás de ese promedio hay dos poblaciones. En las 1113 de inferencia directa —el blanco verdadero ya está en la semilla, lo trae un vecino químico— la posición mediana es 2 y el 79 % cae en el top-10; en las 252 indirectas, donde sólo se llega por anotaciones compartidas, la mediana es 20 y el top-10 baja al 40 %. Las semillas grandes diluyen la señal (Figura 11): el tamaño de la semilla y la posición del blanco se correlacionan ($\rho = 0.45$), y la correlación es positiva dentro de 11 de los 11 organismos con al menos quince casos, así que no es un efecto de mezclar organismos. Una advertencia de lectura: en el 40 % de los casos el blanco comparte puntaje con otras proteínas y su posición es un promedio de empate.




Figura 10: Dónde cae el blanco en las 1365 pseudohuérfanas con semilla informativa. (a) Fracción con el blanco entre las k primeras proteínas de su organismo, frente al azar; la línea punteada es el corte $\text{frank} = 0.1$. (b) frank en escala logarítmica, con la mediana de cada clase.

Hasta dónde confiar en el ranking. Sobre el ranking global (las 399353 proteínas de la red), la curva de recuperación acumulada tiene una pendiente alta en las primeras posiciones que cae al ruido de fondo en $r_G^* = 76$ (Figura 12): una propuesta más abajo que eso no se distingue del azar. Es un corte operativo, no un parámetro identificado: el umbral es $\lambda_\infty + k_\sigma \sigma$ con $k_\sigma = 3$, y con k_σ entre 2 y 4 el corte va de 68 a 88. Ese corte separa dos mecanismos. En la inferencia *directa* el blanco verdadero está entre las semillas (lo trae un vecino químico); en la *indirecta* sólo se llega por la capa de anotaciones. La directa es el 44 % de los casos con ranking y pone el blanco en la posición global mediana 40 (posición 2 dentro del organismo); la indirecta, el 56 %, lo pone en la 185125. De los blancos recuperados, el 82 % lo trae un vecino químico: la mayor parte de la recuperación útil viene de la capa química. (La partición 68 % / 32 % que el código de la versión v3 atribuye a [2] no se verificó contra el artículo.)




Figura 11: Qué diluye la señal, sobre las mismas 1365 pseudohuérfanas. (a) Tamaño de la semilla contra posición del blanco, con los dos ejes en la misma escala. (b) Posición por organismo, en seis de los 16 organismos —uno por grupo taxonómico—; la barra es la mediana y el violín, la distribución.




Figura 12: Arriba: compuestos cuyo blanco verdadero cae antes de la posición l del ranking global. Abajo: su derivada, suavizada, y el umbral $\lambda_\infty + 3\sigma$ que define r_G^* .

Aplicación al organismo foco. De 174 compuestos con actividad fenotípica contra *P. falciparum*, 3 no tienen blanco proteico conocido y los 3 tienen vecinos químicos con blanco. De ellos, 2 reciben una propuesta por encima de r_G^* (2 sugerencias sobre 1 blanco distinto de *P. falciparum*). Es un candidato para ensayar, no un resultado: el embudo es angosto porque la base está recorrida, y la propuesta vale lo que vale la recuperación por encima de r_G^* medida arriba.

5 Contraste con la versión anterior (v4)

Este repositorio es un port del análisis v4 a la base codificada y recortada. Para saber si el port es fiel, las mismas tablas se calcularon antes de los dos cambios y quedaron versionadas como oráculo. El criterio es uno solo: *si el análisis toca la capa química, el recorte lo mueve; si no la toca, no lo mueve*. En desorfanización hay además una segunda causa de cambio: este repositorio corrige un error del modelo que el oráculo tiene (más abajo). De 353 columnas

comparadas hay 0 discrepancias (Figura 13):

- **Priorización**, sin capa química: las 149 columnas son idénticas (149), y los óptimos coinciden con los de un control independiente en 16 de 16 organismos, con diferencia máxima de AUC01 de 0.
- **Desorfanización**, que arma la semilla desde el vecindario químico: 121 de 181 columnas cambian. Contra el oráculo, que tiene el error de la semilla, la semilla nula baja del 83 al 68%, la recuperación sube del 2.6 al 17.5% y r_G^* pasa de 54 a 76, con el mismo tamaño de muestra (7782 pseudohuérfanas en los dos lados). Casi todo ese cambio es la corrección y no el recorte: v4 corregida, fuera de este repositorio, da las mismas clases de semilla para los compuestos que las dos muestras comparten (PROVENANCE.md §3.16). El filtro de promiscuidad pasó de 25 compuestos a 5 —la mayoría no sobrevivió al recorte—, y no mueve la semilla: en la base actual saca 5 compuestos y 0 aristas de la capa de subestructuras.
- **Descriptivos de la base**: 14 de 23 columnas cambian, las que miden componentes químicas.




Figura 13: Columnas comparadas contra el oráculo v4, por análisis. Verde: idéntica; ámbar: cambio explicado por el recorte (en desorfanización, también por la corrección de la semilla); rojo sería una discrepancia.

El port no fue gratuito. La base codificada guarda como enteros lo que antes era texto, y cuatro filtros heredados comparaban contra el texto: el de bioactividad positiva (`== "positive"`) devolvía cero filas y descartaba en silencio 248 545 enlaces; InterPro y OrthoMCL se codificaron desde cero por separado y sus códigos se pisaban; la pseudo-especie sin organismo nunca se excluía y se colaba entre las pseudohuérfanas; y las subestructuras crudas no cruzaban contra la base. Ninguno lanza una excepción, y los cuatro los encontraron las pruebas o la comparación con el oráculo. El detalle está en PROVENANCE.md.

Un error que no era del port. Al armar la semilla de un compuesto, el modelo busca sus vecinos en las aristas de similitud química, que unen *clusters* de compuestos. El código las consultaba con el identificador del *compuesto*, herencia del código original en R, escrito cuando esas aristas eran compuesto-compuesto. Como las dos numeraciones se solapan, no fallaba: devolvía los vecinos de otro cluster, sin relación con el compuesto. El error estaba también en v4, y ahí se encontró; se corrigió con una prueba que arma un cluster señuelo con el mismo número que el compuesto, y que falla con el código anterior. Sólo afecta a la desorfanización: la priorización arma la semilla desde todas las drogas y no pasa por esa búsqueda. Con el error, la semilla de cada compuesto dependía de qué cluster tenía su número, y la codificación reenumeró compuestos y clusters: eso explica por qué, antes de corregirlo, la semilla nula difería entre v4 y este repositorio.

6 Verificación, reproducibilidad y límites

Pruebas. 63 pruebas que corren en menos de medio minuto: integridad de las tablas, ausencia de fuga en la validación cruzada, las métricas contra valores de referencia, las rutas, el entorno, y que toda figura se dibuje sin tocar la base.

Corrida y figuras separadas, y cuánto cuesta cada una. Cada notebook tiene una celda de corrida que carga la base y escribe tablas en `resultados/`, y una sección de resultados que sólo las lee. Rehacer las tablas desde la base lleva unos 45 minutos con 20 procesos, casi todo en el barrido de parámetros y en la desorfanización. Las tablas están versionadas en el repositorio: con ellas, las 36 figuras —declaradas en `comun/figuras.py` junto con las tablas que leen, que son su procedencia— se reproducen en unos cuarenta segundos sin volver a correr ningún modelo, y `make verificar` comprueba en alrededor de un minuto que cada cifra de este informe coincida con ellas. Qué verifica cada figura está en `FIGURAS.md`.

Procedencia. Cada corrida deja un `meta.json` junto a sus tablas con la fecha, el notebook de origen, los parámetros, la fecha de cada tabla de entrada y las versiones de python (3.12.11) y pandas (3.0.5). Ningún número de este informe está escrito a mano: se leen de las tablas con `informe/numeros.py`. El registro de decisiones, con lo que se descartó en cada bifurcación, está en `PROVENANCE.md`.

Límites. El repositorio no reproduce la base misma, que se deriva de datos que no se publican; ni la lista de compuestos promiscuos, que se calcula desde relaciones de subestructura crudas (se versiona como insumo); ni los nombres legibles de las anotaciones, que exigen un diccionario privado.

Referencias

- [1] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.
- [2] Ariel J. Berenstein, María Paula Magariños, Ariel Chernomoretz, and Fernán Agüero. A multilayer network approach for guiding drug repositioning in neglected diseases. *PLoS Neglected Tropical Diseases*, 10(1):e0004300, 2016.
- [3] Donna Katzman McClish. Analyzing a portion of the ROC curve. *Medical Decision Making*, 9(3):190–195, 1989.