

Priorización de blancos terapéuticos sobre una red multicapa

Reproducción sobre una base codificada, con la procedencia registrada

Gonzalo Giordano

Corrida del 2026-09-08 16:30

<https://github.com/Gonzalo174/TDR-GW-AI-course>

Resumen

Dado el genoma de un organismo, ordenar sus proteínas por cuán prometedoras son como blanco de un fármaco. La evidencia experimental es escasa y está repartida de forma muy desigual entre organismos, de modo que la estrategia es propagar lo que se sabe de unas proteínas a otras sobre una red de tres capas: compuestos, proteínas y anotaciones funcionales. Este informe reproduce el análisis completo sobre una versión *codificada* de la base — toda columna es un entero y los diccionarios que traducen esos enteros son privados — y documenta la procedencia de cada resultado junto con la verificación que lo sostiene. La reproducción recupera 252 de 353 columnas idénticas a un oráculo independiente, con 0 discrepancias.

1 El problema

Un programa de descubrimiento de fármacos para una enfermedad desatendida empieza por elegir qué proteína atacar. Esa elección se hace con poca evidencia: para la mayoría de los organismos de interés se conocen apenas decenas de proteínas con actividad medida, sobre genomas de miles.

La hipótesis que explota este trabajo es que la evidencia se puede transferir. Dos proteínas que comparten un dominio funcional tienden a comportarse parecido frente a un compuesto, y dos compuestos químicamente similares tienden a actuar sobre las mismas proteínas. Formalizado, eso es una red de tres capas sobre la que se propaga una señal desde las proteínas con evidencia hacia las que no la tienen.

La base de este trabajo tiene 399 353 proteínas de 16 organismos, 248 545 enlaces de bioactividad positiva y 769 661 afiliaciones a 14 083 dominios InterPro y 76 157 grupos de ortología.

2 Los datos y lo que se les hizo

La base publicada en el repositorio no es la original: se derivó de ella en tres operaciones, cada una con una alternativa defendible que se descartó por una razón explícita (Cuadro 1).

El recorte no es neutral y no se pretende que lo sea: elimina de la base todo lo que no puede contribuir a una propagación desde evidencia positiva. La Figura 1 lo muestra de la forma más directa posible: en la base recortada, la distribución de tamaños de las componentes conexas y la distribución de las componentes que contienen bioactividad positiva coinciden exactamente, porque por construcción no queda ninguna que no la tenga.

La desigualdad de evidencia entre organismos, que es la premisa del método, abarca más de un orden de magnitud: entre 19 y 1985 proteínas con actividad conocida según el organismo (Figura 2). Los organismos se identifican por código y por tipo; el nombre no se publica en ninguna parte del repositorio.

Cuadro 1: Decisiones sobre los datos y su alternativa descartada.

decisión	qué se hizo	alternativa descartada
recorte	Se eliminan las componentes conexas del grafo de similitud química sin ningún compuesto de bioactividad positiva: 2 396 103→831 175 compuestos	Publicar la base entera: 941 MB sólo de aristas, inviable en un repositorio
codificación	Toda notación propia pasa a entero consecutivo en orden aleatorio con semilla fija	Publicar los identificadores reales, que es lo que se quiere evitar
empaquetado	La capa de aristas va partida en dos archivos comprimidos, con las 36 152 622 aristas completas	Subir el umbral de similitud hasta que entre en un archivo: cuesta compuestos




Figura 1: Tamaño de las componentes conexas del grafo de similitud química. Las dos series se superponen: tras el recorte no queda ninguna componente sin bioactividad positiva. Es una verificación de que el recorte hizo exactamente lo que declara.

3 El método

Las anotaciones se puntúan primero por cuánto se enriquecen en proteínas ya conocidas como blanco: un test exacto de Fisher unilateral por categoría, corregido por comparaciones múltiples con Benjamini–Hochberg [1]. Esa puntuación pondera después la propagación hacia las proteínas sin evidencia. El esquema completo, con sus cuatro parámetros, es el de [2].

La métrica es el área parcial bajo la curva ROC restringida a $\text{FPR} \leq 0.10$, corregida por McClish [3] para que el azar valga 0.5 y el clasificador perfecto 1.0. La restricción no es cosmética: sólo importa el extremo del ranking, porque nadie va a ensayar experimentalmente más allá de las primeras decenas de proteínas.

Un detalle de implementación con consecuencia numérica: la pAUC se calcula interpolando el punto exacto ($\text{FPR}_{\max}, \text{TPR}$) antes de integrar. Truncar en el último punto con $\text{FPR} \leq \text{FPR}_{\max}$, que es lo directo, subestima el área.

La validación es *leave-one-species-out*: para evaluar un organismo se retira toda su evidencia




Figura 2: Evidencia disponible por organismo, en escala logarítmica en los dos ejes.

de la semilla y se lo prioriza como si no se supiera nada de él. Que eso esté bien hecho no se asume, se verifica: hay una prueba dedicada que comprueba que ninguna proteína del organismo evaluado sobrevive en la semilla, con su control negativo al lado.

4 Resultados

En su óptimo, la priorización alcanza una mediana de 0.645 de AUC01 entre los 16 organismos evaluados, con un rango de 0.581 a 0.849, y supera el azar en 16 de ellos (Figura 3).




Figura 3: Desempeño por organismo en su óptimo, bajo leave-one-species-out. La línea punteada marca el azar.

Un número óptimo sólo significa algo si el óptimo no es un pico casual. La Figura 4 muestra cuán plano es: el desempeño se sostiene en un entorno amplio de la grilla de parámetros, de modo que la elección no es frágil.




Figura 4: Estabilidad del óptimo en la grilla de parámetros.

5 Verificación

Tres controles, del más barato al más caro.

Las pruebas. 43 pruebas que corren en unos quince segundos: integridad de las tablas, ausencia de fuga en la validación cruzada, las métricas contra valores de referencia, las rutas y el entorno.

El control externo. Los óptimos por organismo se contrastan contra los de una corrida independiente anterior, versionada en el repositorio. Los parámetros óptimos coinciden en los 16 organismos y la diferencia máxima de AUC01 es *exactamente* cero: la reproducción sobre la base codificada no movió un solo dígito del control.

El oráculo. Las mismas tablas calculadas antes del recorte y de la codificación. La comparación es informativa por una asimetría: el recorte *debe* mover los descriptivos de la base, y *no debe* mover la priorización, que no la toca. De 353 columnas comparadas, 252 resultan idénticas, 97 cambian de forma explicada por el recorte y 0 quedan como discrepancia.

El corte cae donde tiene que caer: en `genome_prioritization` las 149 columnas comparadas son idénticas y ninguna cambia, mientras que en `huerfanas`, que construye la semilla desde el vecindario químico, 83 de 177 se mueven. La diferencia se explica sin apelar a nada externo: el conjunto evaluado es el mismo — 7782 pseudohuérfanas de los dos lados — pero el filtro de promiscuidad pasó de descartar 30 compuestos a 7, porque 23 de aquellos 30 no sobrevivieron al recorte, y con menos aristas descartadas más drogas consiguen semilla.

Una corrección que conviene dejar escrita: al diseñar esta comparación agrupé `huerfanas` con `genome_prioritization` entre lo que «no debería moverse». Era incorrecto, y la corrida lo mostró. El criterio correcto es uno solo: si el análisis toca la capa química, el recorte lo mueve.

Lo que casi sale mal

Cuatro errores merecen quedar escritos, porque ninguno se encontró leyendo el código: los encontraron las pruebas o la inspección de las salidas.

La base codificada guarda el tag de actividad como el entero 2, mientras el código heredado filtraba por el texto "positive". Esa comparación no lanza ningún error: devuelve cero filas. El análisis completo seguía adelante produciendo NaN y rankings vacíos, con 248 545 enlaces de evidencia descartados en silencio.

El segundo: InterPro y OrthoMCL se codificaron por separado, cada uno empezando en cero,

de modo que sus códigos se pisan — los 14 083 dominios caen dentro del rango de los 76 157 grupos de ortología. Concatenarlos habría fusionado anotaciones sin relación alguna, y el test de Fisher habría contado proteínas de dos vocabularios distintos como si fueran de uno.

El tercero y el cuarto son el mismo patrón otra vez, y aparecieron ya con los notebooks corriendo. Un filtro escrito como `sp_id != "bioactive"` compara un entero contra un texto y por lo tanto es siempre verdadero: la pseudo-especie que agrupa blancos sin organismo asignado nunca se excluía, y aportaba 67 587 falsas pseudohuérfanas sobre un total de 127 840 — el 53% del conjunto. Y las relaciones de subestructura leídas de los datos crudos entraban sin recodificar, de modo que no cruzaban contra la base y el filtro de promiscuidad descartaba 30 compuestos falsos en lugar de 7 verdaderos.

Los cuatro comparten la misma forma: una columna que pasó a ser un entero codificado, comparada contra el texto que solía contener. Ninguno lanza una excepción; todos devuelven un conjunto vacío o equivocado y dejan que el análisis siga. Es la razón de que las pruebas vayan antes que los resultados, y de que los números se lean de las tablas en vez de escribirse a mano.

6 Procedencia y límites

Cada corrida deja un `meta.json` junto a sus tablas con la fecha, el notebook de origen, los parámetros, la fecha de cada tabla de entrada y las versiones de python (3.12.11) y pandas (3.0.5). El registro completo de decisiones, con lo que se descartó en cada bifurcación y qué es código propio frente a qué se llamó de una librería, está en `PROVENANCE.md`.

Este repositorio no reproduce tres cosas, y conviene decirlo: la base misma, que se deriva de datos que no se publican; los nombres legibles de las anotaciones, que exigen un diccionario privado; y la identidad de los organismos, que es deliberada. Lo que sí se publica es la salida de cada uno de esos pasos y el registro de cómo se produjo.

Referencias

- [1] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.
- [2] Ariel J. Berenstein, María Paula Magariños, Ariel Chernomoretz, and Fernán Agüero. A multilayer network approach for guiding drug repositioning in neglected diseases. *PLoS Neglected Tropical Diseases*, 10(1):e0004300, 2016.
- [3] Donna Katzman McClish. Analyzing a portion of the ROC curve. *Medical Decision Making*, 9(3):190–195, 1989.