

Priorización de blancos terapéuticos sobre una red multicapa


Del análisis v4 a una base codificada, trabajando con Claude

Gonzalo Giordano · proyecto final GW-AI

corrida del 2026-09-24 16:32 · github.com/Gonzalo174/TDR-GW-AI-course

El problema y el método

- ▶ Dado un genoma, **ordenar sus proteínas** por cuán prometedoras son como blanco de un fármaco.
- ▶ La evidencia es escasa y desigual: de 19 a 1985 proteínas con actividad conocida según el organismo.
- ▶ Se **propaga** desde las proteínas con evidencia a las que no la tienen, sobre una red de tres capas.
- ▶ Métrica: **AUC01**, la ROC hasta $\text{FPR} \leq 0.1$ (azar = 0.5). Validación *leave-one-species-out*.



399 353 proteínas · 16 organismos · 248 545 enlaces
positivos · 769 661 afiliaciones

El camino con Claude, I: de v3 a v4

Punto de partida


- ▶ La misma métrica implementada **tres veces**, con tres resultados. Un bug en la pAUC (signo invertido, sin interpolar) sobrevivió meses.
- ▶ Carpetas v3, v4, v5, claude, it0-it3: nada decía qué las distinguía.
- ▶ Una docena de carpetas de scripts nunca corridas completas; una celda de figuras apuntaba a un directorio borrado.

Lo que armamos

- ▶ **Un solo lugar** para el modelo y la métrica (comun/); el modelo sólo cambia con una prueba que lo justifique.
- ▶ Formato fijo de notebook: el ciclo se lee en la celda de corrida; cada salida lleva el número de su notebook y un `meta.json`.
- ▶ **Se recalculó todo** con la métrica corregida, contra una corrida independiente como control.
- ▶ Decisiones escritas: el filtro de promiscuidad (25 compuestos, 12 % de la capa) se aplica.

El camino con Claude, II: la base codificada

- 1 **Acondicionar la base para publicarla** (siguiente diapositiva).
- 2 **Pruebas antes que resultados.** Encontraron cuatro fallas *silenciosas*, todas iguales: un entero codificado comparado contra el texto que solía ser.
 - == "positive" daba 0 filas: 248 545 enlaces descartados sin error
 - la pseudo-especie sin organismo se colaba entre las pseudohuérfanas
- 3 **Contrastar con v4:** 353 columnas, 0 discrepancias. Priorización idéntica (149/149); control 16/16, $\Delta AUC01 = 0$.
- 4 **Entregables sin cifras a mano**, y corrida separada de figuras: 36 figuras en ~ 40 s.



Verde: idéntica a v4. Ámbar: cambio que el recorte explica (en huérfanas, también la corrección de abajo). Si el análisis toca la capa química, el recorte lo mueve; si no, no.

Un error heredado, no del port. La semilla buscaba vecinos químicos con el id del compuesto en tablas de *clusters*. Hallado en v4 y corregido con una prueba: huérfanas recuperadas, 2.6 $\rightarrow$ 17.5 %.

Ocultar los nodos: la base que se puede publicar

Recortar

Se eliminan las componentes químicas sin ninguna bioactividad positiva: no pueden aportar a la propagación.

2 396 103 → 831 175

compuestos (34.7 %); toda la evidencia positiva sobrevive

Codificar

Todo identificador pasa a un entero en orden aleatorio (semilla 20260908). Los diccionarios quedan privados; ninguna especie se nombra.

2 902 385

identificadores en 11 diccionarios

Empaquetar


Las aristas se parten en dos .csv.gz de menos de 100 MB, sin subir el umbral de similitud (que costaba compuestos).

36 152 622

aristas, completas

El costo. Se publica el tipo de organismo, que el modelo usa: 3 de 16 son únicos en su combinación y quedan identificables. Y los nombres de las anotaciones no se pueden reconstruir.

Resultados I: priorizar un genoma sin su propia evidencia





- ▶ Supera al azar en los **16** organismos; AUC01 mediana 0.645 (0.581–0.849).
- ▶ Los 4 primeros son los 4 **protozoos parásitos**.
- ▶ Lo decide un solo parámetro, β : penalizar las categorías grandes. $\beta > 0$ en 15/16 óptimos; $\beta = 1$ está $2.45\times$ sobrerrepresentado en el top-10.
- ▶ El óptimo es una meseta: las 20 mejores quedan a menos del 2.1 % del máximo.

$$\text{score}_i = k_i^{\lambda-1} \sum_{l \in A(i)} |C_l|^{-\beta} \text{RS}_l \sum_{j \in S \cap C_l} \frac{w_j}{k_j^\lambda}$$

$|C_l|^{-\beta}$: el grado de la categoría l —cuántas proteínas la comparten— elevado a $-\beta$. k_i : anotaciones de la proteína; RS_l : relevancia (Fisher + BH); S : semilla. $\beta = 0$ la apaga: es G'_r contra G'_{rk} .

$\beta = 0$ contra $\beta = 1$: sobre quién actúa la penalización

Se fija el mejor $(\alpha, \lambda, \gamma)$ *dentro* de $\beta = 1$ y se mueve sólo β a 0. Grupo de prueba, las quinasas —categoría grande y promiscua—: 391 de 14 083 dominios, pero el 3.4 % de las proteínas de un genoma típico.



Apagarla cuesta AUC01 en 15 de los 16 organismos
(mediana 0.057, máx. 0.275).





Con $\beta = 0$ la cabeza se inunda de quinasas: hasta $37\times$ el azar en 8 organismos. Con $\beta = 1$ no pasa de 3.5 en ninguno.

Y el desplazamiento es **específico**: las quinasas bajan 10.3 percentiles en 15/16 organismos y el resto no se mueve. β no reordena el ranking: saca del tope lo que estaba ahí por una anotación que tiene medio genoma.

Resultados II: proponer el blanco de un compuesto huérfano

Se le borra toda la bioactividad a 7782 compuestos con un único blanco conocido, y se lo busca desde su vecindario químico.



- ▶ Se recupera en el **17.5 %**, y la causa está medida: todo depende de qué llega a la semilla.
- ▶ El límite es la **cobertura química**, no el modelo: el techo va del 3.9 al 33 % por organismo.



Las capas de la diapositiva 2 —compuestos, proteínas, anotaciones—, con los nodos siempre en el mismo lugar: lo que cambia es qué aristas sobreviven. Anillo naranja: el huérfano. Verde: su blanco.


Resultados III: cuando hay semilla informativa

$\text{frank} < 0.1$ es quedar entre las primeras ~ 656 : no discrimina. Con la posición exacta, sobre las 1 365 con semilla informativa:



- ▶ **1.º** en el 30 %, **top-10** en el 72 % (azar: 0.13 %).
- ▶ **Directa** (el vecino trae el blanco): mediana 2. **Indirecta** (sólo anotaciones): 20.
- ▶ La mediana de las dos clases queda muy por debajo del corte (~ 656): no es que apenas lo pasen.

Resultados III (cont.): qué diluye la señal



- ▶ Cuanto más grande la semilla, más abajo cae el blanco: $\rho = 0.45$, positiva *dentro* de 11 de los 11 organismos con casos suficientes.
- ▶ Panel (b): seis organismos, uno por grupo taxonómico. La mediana se mueve entre ellos, pero la cabeza de cada distribución está siempre en las primeras posiciones.
- ▶ En el 40 % de los casos el blanco empata en puntaje: su posición es un promedio de empate.

Qué me llevo

Del problema

- ▶ La propagación prioriza genomas de los que no se sabe nada, y lo que la hace funcionar es penalizar las categorías grandes.
- ▶ Para desorfanizar, el cuello de botella es la cobertura química: con semilla informativa el blanco cae en el top-10 el 72 % de las veces.
- ▶ **Siguiente paso: ponerlo a disposición de la comunidad** —priorización, algoritmo y base codificada— para que cualquier grupo pueda correr su genoma y discutir los rankings.

Del trabajo con Claude

- ▶ **Generar los resultados con código:** es lo que hace controlable la trazabilidad. Cada cifra se lee de una tabla y cada decisión queda escrita (PROVENANCE.md).
- ▶ **Separar la corrida de las figuras:** iterar sobre una figura cuesta segundos, no los tres cuartos de hora de la corrida.
- ▶ **Soltura con el agente,** con los modos del curso: planificar antes de tocar, delegar la exploración, pedir la prueba antes que el resultado.
- ▶ Y lo más caro: **las pruebas antes que los resultados** —las fallas que importan no lanzan excepciones.