

Priorización de blancos terapéuticos sobre una red multicapa


Del análisis v4 a una base codificada, trabajando con Claude

Gonzalo Giordano · proyecto final GW-AI

corrida del 2026-09-10 10:21 · github.com/Gonzalo174/TDR-GW-AI-course

El problema y el método

- ▶ Dado un genoma, **ordenar sus proteínas** por cuán prometedoras son como blanco de un fármaco.
- ▶ La evidencia es escasa y desigual: de 19 a 1985 proteínas con actividad conocida según el organismo.
- ▶ Se **propaga** desde las proteínas con evidencia a las que no la tienen, sobre una red de tres capas.
- ▶ Métrica: **AUC01**, la ROC hasta $\text{FPR} \leq 0.1$ (azar = 0.5). Validación *leave-one-species-out*.



399 353 proteínas · 16 organismos · 248 545 enlaces
positivos · 769 661 afiliaciones

El camino con Claude, I: de v3 a v4

Punto de partida


- ▶ La misma métrica implementada **tres veces**, con tres resultados. Un bug en la pAUC (signo invertido, sin interpolar) sobrevivió meses.
- ▶ Carpetas v3, v4, v5, claude, it0-it3: nada decía qué las distinguía.
- ▶ Una docena de carpetas de scripts nunca corridas completas; una celda de figuras apuntaba a un directorio borrado.

Lo que armamos

- ▶ **Un solo lugar** para el modelo y la métrica (comun/); el modelo sólo cambia con una prueba que lo justifique.
- ▶ Formato fijo de notebook: el ciclo se lee en la celda de corrida; cada salida lleva el número de su notebook y un `meta.json`.
- ▶ **Se recalculó todo** con la métrica corregida, contra una corrida independiente como control.
- ▶ Decisiones escritas: el filtro de promiscuidad (30 compuestos, 12 % de la capa) se aplica.

El camino con Claude, II: la base codificada

- 1 **Acondicionar la base para publicarla** (siguiente diapositiva).
- 2 **Pruebas antes que resultados.** Encontraron cuatro fallas *silenciosas*, todas iguales: un entero codificado comparado contra el texto que solía ser.
 - == "positive" daba 0 filas: 248 545 enlaces descartados sin error
 - la pseudo-especie aportaba el 53 % de las pseudohuérfanas
- 3 **Contrastar con v4:** 353 columnas, 0 discrepancias. Priorización idéntica (149/149); control 16/16, $\Delta AUC01 = 0$.
- 4 **Entregables sin cifras a mano**, y corrida separada de figuras: 35 figuras en ~ 40 s.



Verde: idéntica a v4. Ámbar: cambio que el recorte explica. Si el análisis toca la capa química, el recorte lo mueve; si no, no.

Ocultar los nodos: la base que se puede publicar

Recortar

Se eliminan las componentes químicas sin ninguna bioactividad positiva: no pueden aportar a la propagación.

2 396 103 → 831 175

compuestos (34.7 %); toda la evidencia positiva sobrevive

Codificar

Todo identificador pasa a un entero en orden aleatorio (semilla 20260908). Los diccionarios quedan privados; ninguna especie se nombra.

2 902 385

identificadores en 11 diccionarios

Empaquetar


Las aristas se parten en dos .csv.gz de menos de 100 MB, sin subir el umbral de similitud (que costaba compuestos).

36 152 622

aristas, completas

El costo. Se publica el tipo de organismo, que el modelo usa: 3 de 16 son únicos en su combinación y quedan identificables. Y los nombres de las anotaciones no se pueden reconstruir.

Resultados I: priorizar un genoma sin su propia evidencia




- ▶ Supera al azar en los **16** organismos; AUC01 mediana 0.645 (0.581–0.849).
- ▶ Los 4 primeros son los 4 **protozoos parásitos**.
- ▶ Lo decide un solo parámetro, β : penalizar las categorías grandes. $\beta > 0$ en 15/16 óptimos; $\beta = 1$ está $2.45\times$ sobrerrepresentado en el top-10.
- ▶ El óptimo es una meseta: las 20 mejores combinaciones quedan a menos del 2.1 % del máximo.

Resultados II: proponer el blanco de un compuesto huérfano


Se le borra toda la bioactividad a 7782 compuestos con un único blanco conocido, y se lo busca desde su vecindario químico.

- ▶ Se recupera en el **3.4 %**. La causa está medida:
- ▶ el **69 %** no tiene ningún vecino químico con blanco;
- ▶ si la semilla comparte una anotación con el blanco: **98.9 %**; si no, 0.0 %.
- ▶ El límite es la cobertura química, no el modelo: el techo va del 0.7 al 16 % por organismo.



Rojo: sin semilla. Ámbar: semilla sin anotación en común. Verde: semilla informativa.

Resultados III: cuando hay semilla informativa



$\text{frank} < 0.1$ es quedar entre las primeras ~ 1309 : no discrimina. Con la posición exacta:

- ▶ **1.º** en el 26 %, **top-10** en el 62 % (azar: 0.13 %).
- ▶ **Directa** (el vecino trae el blanco): mediana 2. **Indirecta** (sólo anotaciones): 29.5.
- ▶ Semillas grandes diluyen: $\rho = 0.42$, positiva en 8/8 organismos.

Qué me llevo

Del problema

- ▶ La propagación prioriza genomas de los que no se sabe nada, y lo que la hace funcionar es penalizar las categorías grandes.
- ▶ Para desorfanizar, el cuello de botella es la cobertura química: cuando hay semilla informativa, el blanco cae en el top-10 el 62 % de las veces.
- ▶ Siguiente paso: ampliar la semilla (umbral de similitud por debajo de 0.8, KEGG).

Del trabajo con Claude

- ▶ Las pruebas antes que los resultados: las fallas caras no lanzan excepciones.
- ▶ Cada cifra se lee de una tabla; cada decisión queda escrita con la alternativa que se descartó (PROVENANCE.md).
- ▶ Separar la corrida de las figuras: iterar sobre una figura cuesta segundos, no la corrida.