

Priorización de blancos terapéuticos y desorfanización de compuestos bioactivos sobre un modelo de red multicapa quimiogenómica

Reproducción y extensión del modelo de TDR Targets sobre 16 especies

Gonzalo Giordano

7 de septiembre de 2026

Resumen

El desarrollo de fármacos para enfermedades desatendidas está limitado por la escasez de incentivos de mercado, lo que vuelve al reposicionamiento de drogas y a la priorización computacional de blancos una estrategia central. Sobre la base del modelo de red multicapa propuesto por Berenstein y colaboradores [1] y de su implementación productiva en TDR Targets [2], en este trabajo se reconstruye el pipeline completo — caracterización de la red, barrido de parámetros del propagador, validación cruzada y desorfanización de compuestos — sobre una instantánea actualizada de la base de datos, y se lo extiende con tres aportes propios: (i) una caracterización cuantitativa de las capas y de su conectividad cruzada que expone la asimetría de cobertura entre organismos modelo y patógenos; (ii) un criterio de *plateau* y de consistencia entre especies que muestra que el óptimo del barrido no es un punto aislado sino una meseta amplia, con $\beta = 1$ como único parámetro fuertemente seleccionado; y (iii) un criterio operativo de decisión, r_G^* , derivado de la curva de recuperación global de pseudo-huérfanas, que define a partir de qué ranking una sugerencia deja de ser distinguible del azar. La red integra $3,53 \times 10^6$ registros de bioactividad compuesto-proteína sobre $3,99 \times 10^5$ proteínas de 30 especies. El barrido sobre 120 combinaciones de parámetros y 16 especies alcanza $AUC_{0,1}$ entre 0,58 (*M. tuberculosis*) y 0,85 (*T. cruzi*), reproduciendo los valores de la implementación de referencia. Sobre *P. falciparum* el método reduce 233 compuestos fenotípicamente activos a 12 casos tratables y produce dos sugerencias de blanco con $r_G = 15,5$, muy por debajo del umbral $r_G^* = 54$.

Índice

1	Introducción	3
2	Materiales y métodos	3
2.1	Datos	3
2.2	El propagador y sus cuatro parámetros	4
2.3	Métrica de evaluación	4
2.4	Reproducibilidad	4
3	Resultados	5
3.1	Dimensiones y cobertura de la red	5
3.2	Estructura de la capa química	7
3.3	Conectividad cruzada entre especies	7
3.4	Calidad de la capa de bioactividad y compuestos promiscuos	8
3.5	Priorización de blancos: barrido de parámetros	10
3.6	Forma del óptimo: <i>plateau</i> y consistencia	13
3.7	Desorfanización: calibración con pseudo-huérfanas	16

3.8	Un umbral de decisión: r_G^*	19
3.9	Aplicación: compuestos antipalúdicos huérfanos	20
4	Discusión	21
5	Conclusiones	22

1 Introducción

Las enfermedades tropicales desatendidas afectan a alrededor de 1500 millones de personas, mayoritariamente en países de ingresos bajos y medios, y han recibido históricamente una inversión en investigación y desarrollo desproporcionadamente baja respecto de su carga de enfermedad [2]. En ese contexto, el reposicionamiento de fármacos y la priorización computacional de blancos proteicos son estrategias atractivas: permiten aprovechar información experimental ya generada sobre organismos intensamente estudiados para guiar decisiones sobre patógenos con muy poca caracterización propia.

El modelo de red multicapa de Berenstein et al. [1] formaliza esa idea. La red tiene dos tipos de nodos — compuestos y proteínas — y tres clases de enlaces: (a) similitud química entre compuestos, (b) asociaciones de bioactividad compuesto–proteína medidas experimentalmente, y (c) relaciones funcionales entre proteínas, mediadas por su pertenencia a categorías de ortología y de dominios proteicos. La priorización de blancos se plantea entonces como un problema de propagación de un recurso (*druggability*) desde un conjunto semilla de proteínas con inhibidores conocidos hacia el resto del proteoma, a través de las categorías funcionales compartidas. El resultado es un *Network Druggability Score* (NDS) por proteína.

Este informe persigue tres objetivos:

1. **Caracterizar** la instantánea actual de la base de datos: qué tamaño tiene cada capa, cómo se distribuye la información entre especies y qué artefactos introduce la capa de bioactividad (Sección 3.1).
2. **Reproducir y auditar** el procedimiento de priorización: barrer el espacio de parámetros del propagador, medirlo con validación cruzada interna, verificar que los óptimos coinciden con la implementación de referencia, y caracterizar la *forma* del óptimo, no sólo su ubicación (Sección 3.5).
3. **Aplicar** el modelo al problema inverso — dado un compuesto activo sin blanco conocido, sugerir proteínas candidatas — calibrando el procedimiento con un experimento de pseudo-huérfanas y derivando un umbral de decisión explícito, que luego se usa sobre compuestos antipalúdicos huérfanos reales (Secciones 3.7 y 3.9).

Respecto del trabajo original, los aportes propios de esta realización son la caracterización cuantitativa de la conectividad cruzada entre especies (Sección 3.3), el diagnóstico y la corrección del sesgo por compuestos promiscuos de bajo peso molecular (Sección 3.4), el análisis de *plateau* y consistencia del barrido (Sección 3.6) y la definición del umbral r_G^* (Sección 3.8).

2 Materiales y métodos

2.1 Datos

Todos los resultados provienen de una única instantánea de la base de datos, cuyas tablas y fechas de corte se registran automáticamente en los archivos `*_meta.json` de cada corrida. Las tablas centrales son las bioactividades compuesto–proteína (corte 7 de agosto de 2026), las bioactividades compuesto–organismo (4 de junio de 2026), las afiliaciones InterPro [3] (10 de junio de 2026) y OrthoMCL [4] (25 de agosto de 2026), y los *clusterings* químicos por *fingerprint* [5] y por subestructura (13 de mayo de 2026). El análisis se ejecutó con Python 3.12.2 y pandas 2.2.3.

El estudio se restringe a 16 especies que combinan organismos modelo intensamente caracterizados (*H. sapiens*, *M. musculus*, *S. cerevisiae*, *E. coli*, *A. thaliana*, *D. melanogaster*, *C. elegans*, *O. sativa*, *D. discoideum*) y patógenos de interés sanitario (*M. tuberculosis*, *S. aureus*, *P. falciparum*, *T. brucei*, *T. cruzi*, *L. major*, *C. albicans*).

2.2 El propagador y sus cuatro parámetros

Sea $A = (a_{i\ell})$ la matriz de afiliación proteína–categoría, con $k_i = \sum_{\ell} a_{i\ell}$ el número de categorías de la proteína i y $|\ell| = \sum_i a_{i\ell}$ el tamaño de la categoría ℓ . Sea w_j el peso semilla de la proteína j (no nulo sólo para proteínas con inhibidores conocidos). El puntaje se calcula en dos pasos: primero cada categoría acumula recurso de sus proteínas semilla,

$$f_{\ell} = \underbrace{|\ell|^{-\beta}}_{\text{corrección de tamaño}} \cdot \underbrace{\text{RS}_{\ell}(\alpha)}_{\text{relevancia}} \cdot \sum_j a_{j\ell} \frac{w_j}{k_j^{\lambda_j}}, \quad (1)$$

y luego cada proteína recoge el recurso de sus categorías,

$$\text{NDS}_i = k_i^{\lambda_i - 1} \sum_{\ell} a_{i\ell} f_{\ell}. \quad (2)$$

Los cuatro parámetros libres tienen lecturas distintas:

α (**relevancia**). RS_{ℓ} se obtiene de un test exacto de Fisher que evalúa el enriquecimiento de proteínas semilla dentro de la categoría ℓ ; α reescala esos p -valores (corregidos por FDR [6]) para convertirlos en un peso. Con $\alpha = 0$ todas las categorías pesan igual.

β (**tamaño de categoría**). Penaliza a las categorías muy pobladas, que de otro modo dominan la propagación por puro volumen. El caso $\beta = 0$ corresponde a la red G'_r del trabajo original y $\beta > 0$ a G'_{rk} .

λ (**difusión**). Controla cuánto se diluye el recurso de una proteína entre sus categorías. Además de los valores fijos $\lambda \in \{0; 0,5; 1\}$ se admite un modo *híbrido* en el que λ se calcula por proteína como $\lambda_i = (k_i/k_{\max})^{\gamma}$.

γ (**exponente del híbrido**). Sólo interviene cuando λ es híbrido; con λ fijo el modelo lo ignora. Por eso la grilla efectiva tiene 120 combinaciones y no 240.

La grilla barrida fue $\alpha \in \{0; 0,3; 0,6; 0,9; 1,2\}$, $\beta \in \{0; 0,5; 1; 1,5\}$, $\lambda \in \{0; 0,5; 1; \text{híbrido}\}$ y $\gamma \in \{0,8; 1,0; 1,2\}$.

2.3 Métrica de evaluación

Para cada especie y cada combinación de parámetros se evalúa la capacidad del NDS de recuperar las proteínas *druggables* conocidas de esa especie. Dado que en la práctica sólo interesa el extremo superior del ranking, la métrica no es el área bajo la curva ROC completa sino el área parcial restringida a $\text{FPR} \leq 0,10$, normalizada y corregida por el método de McClish [7] para que el azar valga 0,5 y el clasificador perfecto valga 1. Notamos esta métrica $\text{AUC}_{0.1}$. Se reporta además la AUC global como referencia.

2.4 Reproducibilidad

Cada notebook escribe sus tablas, figuras y un `meta.json` con los parámetros, las versiones de las librerías y las fechas de corte de cada tabla consumida. Los resultados de esta corrida se validaron contra la implementación de referencia (`genoma_completo_v5`) exigiendo coincidencia exacta del vector $(\alpha, \beta, \lambda, \gamma)$ óptimo en las 16 especies.

3 Resultados

3.1 Dimensiones y cobertura de la red

La Tabla 1 resume el tamaño de cada capa. La red integra $3,53 \times 10^6$ registros de bioactividad compuesto–proteína, de los cuales 248 545 constituyen enlaces positivos y 144 552 negativos; el resto queda como indeterminado. La capa de afiliaciones aporta 769 661 enlaces proteína–categoría sobre 14 083 categorías InterPro y 76 157 categorías OrthoMCL.

Tabla 1: Dimensiones de las capas del modelo en la instantánea analizada.

Capa	Entidad	n
1 — compuestos	compuestos con bioactividad	949 054
2 — proteínas	proteínas (V_P)	399 352
2 — proteínas	especies	30
3 — afiliaciones	categorías InterPro	14 083
3 — afiliaciones	categorías OrthoMCL	76 157
2–3 (afiliación)	enlaces proteína–categoría	769 661
1–2 (bioactividad)	registros compuesto–proteína	3 526 999
1–2 (bioactividad)	enlaces E_{DP} positivos	248 545
1–2 (bioactividad)	enlaces E_{DP} negativos	144 552
1–2 (bioactividad)	proteínas <i>druggables</i>	19 650
fenotípica	registros compuesto–organismo	931 971

La distribución de esa información entre especies es fuertemente desigual (Figura 1). *H. sapiens* concentra 1985 proteínas *druggables* sobre 18 052 proteínas anotadas, mientras que patógenos como *T. cruzi* y *L. major* tienen 29 y 30 respectivamente sobre proteomas de 19 245 y 6564 proteínas. Es exactamente el desbalance que justifica el enfoque: sin transferencia de información entre organismos, los patógenos no tienen suficiente evidencia propia para sostener una priorización.

La cobertura de anotaciones muestra un patrón complementario. La afiliación OrthoMCL es casi universal en eucariotas (*P. falciparum* y *L. major* alcanzan el 100 %; *A. thaliana*, el 99,8 %), mientras que la cobertura InterPro es sistemáticamente menor y cae justamente en los protozoos: 44,7 % en *P. falciparum*, 40,3 % en *T. brucei* y 39,6 % en *T. cruzi*, frente a 65,4 % en *H. sapiens* y 71,5 % en *M. musculus*. La consecuencia práctica es que en los patógenos de interés la propagación descansa más sobre ortología que sobre dominios.






Figura 1: Disponibilidad de información por especie: tamaño del proteoma, cobertura de anotaciones InterPro y OrthoMCL, y número de proteínas *druggables*. El contraste entre organismos modelo y patógenos motiva la transferencia de información en red.

Las categorías funcionales tienen una distribución de grado marcadamente sesgada (Figura 2). Unas pocas categorías InterPro genéricas — dominio quinasa (IPR000719, 9576 proteínas), sitios de unión a ATP (IPR017452, 3772) o dedos de zinc (IPR013087, 3605) — concentran una fracción desproporcionada de los enlaces, mientras que la enorme mayoría de las categorías conecta a un puñado de proteínas. Esta cola pesada es precisamente lo que el parámetro β de la Ecuación (1) está diseñado para compensar.



(a) Distribución de grado.




(b) Enlaces acumulados por tramo de grado.


Figura 2: Grado de las categorías de afiliación (InterPro y OrthoMCL). Un número reducido de categorías muy pobladas acumula una fracción sustancial de los enlaces proteína–categoría.

3.2 Estructura de la capa química

Los *clusterings* químicos por *fingerprint* y por subestructura producen distribuciones de tamaño de *cluster* igualmente sesgadas (Figura 3a): el *cluster* mayor por *fingerprint* agrupa 510 compuestos, pero la moda está en tamaño 1. El grafo de similitud química está además muy fragmentado (Figura 3b): sobre 192 742 componentes conexas, la componente gigante contiene 137 050 *clusters*, de los cuales sólo 2818 tienen alguna bioactividad asociada. Es decir, la mayor parte del espacio químico está poblada por compuestos sin información experimental de blanco: el problema de las moléculas huérfanas no es marginal sino la situación por defecto.



(a) Tamaños de *cluster*.



(b) Componentes conexas.

Figura 3: Estructura de la capa química. La fragmentación del grafo de similitud y la escasez de bioactividad anotada en la componente gigante delimitan el alcance de la inferencia química.

3.3 Conectividad cruzada entre especies

Para cuantificar cuánta información puede efectivamente transferirse entre organismos se calcularon dos matrices de conectividad: el número de categorías de afiliación compartidas entre cada par de especies (Figura 4a) y el número de compuestos con bioactividad positiva compartidos (Figura 4b).

Las dos matrices cuentan historias distintas. La conectividad por anotaciones es alta y bien estructurada por filogenia: *H. sapiens* y *M. musculus* comparten 13 740 categorías, los

tripanosomátidos entre sí comparten entre 5669 y 7287, y *P. falciparum* mantiene entre 2400 y 3200 categorías compartidas con casi todos los eucariotas del panel. Incluso los pares filogenéticamente distantes conservan cientos o miles de categorías en común.

La conectividad química, en cambio, es órdenes de magnitud más pobre y está dominada por un único nodo. *H. sapiens* comparte 648 compuestos con *P. falciparum*, 512 con *M. musculus* y 819 con *S. cerevisiae*; pero *P. falciparum* comparte apenas 16 compuestos con *L. major* y 12 con *T. cruzi*. Fuera de la fila y la columna humanas, la matriz es prácticamente vacía.

Esta asimetría es, a nuestro juicio, el hallazgo estructural más relevante de la caracterización: el puente que sostiene la transferencia de información entre patógenos no es la evidencia química directa — que casi no existe entre pares de patógenos — sino la capa de afiliaciones funcionales. Justifica *a posteriori* que el propagador de las Ecuaciones (1) y (2) opere sobre categorías y no sobre similitud química.




Figura 4: Conectividad cruzada entre las 16 especies. La capa de afiliaciones funcionales (a) conecta densamente a todos los organismos, mientras que la evidencia química compartida (b) es escasa y está concentrada en *H. sapiens*.

3.4 Calidad de la capa de bioactividad y compuestos promiscuos

La clasificación de los $3,53 \times 10^6$ registros compuesto–proteína arroja 88,7 % de registros indeterminados, 7,0 % positivos y 4,1 % negativos, con sólo un 0,17 % de registros inconsistentes (Figura 5). La baja tasa de inconsistencia indica que el criterio de consolidación de bioactividades es estable.




Figura 5: Clasificación de los registros de bioactividad compuesto-proteína. La abrumadora mayoría queda como indeterminada; los inconsistentes son marginales.

Un problema más serio aparece al examinar la promiscuidad. Un puñado de compuestos está asociado a decenas de miles de proteínas parentales: el más extremo (`drug_id` 166536, $MW = 114,1$) aparece vinculado a 30 584 proteínas; le siguen 1116907 ($MW = 128,2$, 24 544 proteínas) y 163058 ($MW = 142,2$, 21 196 proteínas). Todos ellos son moléculas muy pequeñas: no se trata de inhibidores promiscuos genuinos sino, casi con certeza, de fragmentos, buffers y artefactos de anotación.

Estos compuestos son tóxicos para el modelo porque actúan como atajos que conectan proteínas sin ninguna relación funcional real. Se definió por lo tanto un filtro conjunto sobre peso molecular y promiscuidad, $MW < 150$ y $N_{\text{parentales}} > 100$, cuyo efecto se muestra en la Tabla 2: elimina apenas 30 compuestos (0,015 % del total) pero remueve 104 075 aristas, el 11,98 % de la capa de bioactividad. La relación entre ambas cifras — tres órdenes de magnitud — es la que justifica el filtro: es una intervención mínima con un efecto estructural grande. La Figura 6 muestra que la elección de los umbrales no es crítica, ya que la curva de aristas filtrables se estabiliza en un rango amplio.

Tabla 2: Impacto del filtro de compuestos promiscuos de bajo peso molecular.

Criterio	Compuestos	% compuestos	Aristas	% aristas
$MW < 150$ y $N_{\text{par.}} > 100$	30	0,015	104 075	11,98




Figura 6: Promiscuidad por compuesto en función del peso molecular y curva de sensibilidad del filtro. Los compuestos hiperconectados se agrupan en la región de bajo peso molecular, compatible con fragmentos y artefactos de anotación más que con farmacología real.

Este filtro se aplica aguas arriba de todo el análisis de desorfanización de la Sección 3.7.

3.5 Priorización de blancos: barrido de parámetros

Con la red caracterizada y filtrada, se barrieron las 120 combinaciones válidas de $(\alpha, \beta, \lambda, \gamma)$ sobre cada una de las 16 especies, evaluando en cada caso la recuperación de las proteínas *druggables* conocidas. La Figura 7 muestra el conjunto de positivos disponible por especie, que fija el techo estadístico de cada evaluación.




Figura 7: Número de proteínas *druggables* (positivos) por especie. Las especies con pocos positivos producen estimaciones de $AUC_{0.1}$ con mayor varianza.

Control frente a la implementación de referencia. Antes de interpretar los resultados se verificó que la reimplementación reproduce la corrida de referencia `genoma_completo_v5`: el vector de parámetros óptimo coincide en las 16 especies y las diferencias de $AUC_{0.1}$ son numéricamente despreciables (Figura 8). El pipeline queda así validado como reproducción fiel antes de introducir cualquier extensión.




Figura 8: Control de reproducibilidad contra la implementación de referencia. Coincidencia de los parámetros óptimos en las 16 especies.

Desempeño por especie. La Tabla 3 y la Figura 9 resumen el resultado. El $AUC_{0,1}$ óptimo varía entre 0,581 (*M. tuberculosis*) y 0,849 (*T. cruzi*). El ordenamiento es informativo: los mejores desempeños corresponden a *T. cruzi* (0,849), *T. brucei* (0,789), *L. major* (0,743) y *P. falciparum* (0,736) — es decir, a los protozoos patógenos, que son justamente el objetivo del método — mientras que los peores corresponden a *M. tuberculosis* (0,581), *S. cerevisiae* (0,581), *S. aureus* (0,591) y *H. sapiens* (0,594).

La lectura no es que el método funcione mejor en protozoos por alguna virtud biológica, sino que allí la señal disponible es más aprovechable: en especies con muchos positivos y con *druggables* distribuidos por todo el proteoma — el caso humano — la propagación desde semillas ya no agrega tanto sobre lo que se sabe. La AUC global, en cambio, es alta y relativamente uniforme (entre 0,743 y 0,883), lo que confirma que la métrica restringida al extremo del ranking es la que discrimina realmente entre configuraciones.

Tabla 3: Parámetros óptimos y desempeño por especie. N : proteínas evaluadas; $\lambda = \text{híb.}$ indica modo híbrido, en el que rige γ .

Especie	$(\alpha, \beta, \lambda, \gamma)$	$\text{AUC}_{0.1}$	AUC	Youden	N
<i>T. cruzi</i>	(0,0; 1,0; 1,0; 0,8)	0,849	0,883	0,721	19 241
<i>T. brucei</i>	(0,3; 1,5; híb.; 0,8)	0,789	0,844	0,642	8633
<i>L. major</i>	(0,0; 1,5; 0,5; 0,8)	0,743	0,859	0,679	6564
<i>P. falciparum</i>	(1,2; 1,0; 1,0; 0,8)	0,736	0,841	0,624	5495
<i>A. thaliana</i>	(0,0; 1,0; 0,5; 0,8)	0,683	0,828	0,567	21 714
<i>C. elegans</i>	(0,3; 1,5; 1,0; 0,8)	0,664	0,781	0,553	27 425
<i>D. discoideum</i>	(0,0; 1,0; 1,0; 0,8)	0,652	0,871	0,759	13 088
<i>C. albicans</i>	(1,2; 1,0; 0,5; 0,8)	0,645	0,868	0,661	6040
<i>O. sativa</i>	(1,2; 1,0; 0,5; 0,8)	0,644	0,843	0,580	22 012
<i>D. melanogaster</i>	(0,0; 1,0; 1,0; 0,8)	0,614	0,812	0,570	10 695
<i>M. musculus</i>	(0,3; 1,0; híb.; 0,8)	0,611	0,818	0,538	18 185
<i>H. sapiens</i>	(0,0; 0,5; 1,0; 0,8)	0,594	0,769	0,481	16 301
<i>S. aureus</i>	(0,3; 0,5; 0,5; 0,8)	0,591	0,878	0,715	2187
<i>E. coli</i>	(1,2; 1,0; 1,0; 0,8)	0,588	0,820	0,565	4533
<i>S. cerevisiae</i>	(0,9; 0,0; 0,0; 0,8)	0,581	0,743	0,445	6093
<i>M. tuberculosis</i>	(1,2; 1,0; híb.; 0,8)	0,581	0,866	0,656	4073




Figura 9: $\text{AUC}_{0.1}$ óptima por especie. Los protozoos patógenos, objetivo primario del método, ocupan las primeras posiciones.

La Figura 10 detalla el caso de *P. falciparum*: la curva ROC completa y la distribución de NDS bajo la configuración óptima $(\alpha, \beta, \lambda, \gamma) = (1,2; 1,0; 1,0; 0,8)$. La separación entre proteínas *druggables* y el resto se concentra en la cola derecha de la distribución de puntajes, que es exactamente la región que $\text{AUC}_{0.1}$ mide.




Figura 10: *P. falciparum* bajo su configuración óptima: curva ROC global (izquierda) y distribución de NDS discriminada por condición de *druggable* (derecha).

3.6 Forma del óptimo: *plateau* y consistencia

Reportar un único vector óptimo por especie invita a una lectura equivocada, la de que el método requiere una calibración fina y específica. Para evaluar eso se analizó la *forma* del óptimo, no sólo su ubicación.

El óptimo es una meseta. La Tabla 4 muestra la caída relativa de $AUC_{0.1}$ al pasar del mejor vector al quinto, décimo y vigésimo mejor, junto con el número de combinaciones que quedan dentro de tolerancias absolutas de 0,001, 0,005 y 0,01. La caída al quinto mejor no supera el 1,2 % en ninguna especie y es inferior al 0,3 % en la mitad de ellas. En *S. cerevisiae*, 48 de las 120 combinaciones caen dentro de 0,01 del máximo; en *M. musculus*, 44; en *A. thaliana*, 35. El óptimo no es un pico agudo sino una meseta amplia (Figura 11), lo que implica que el desempeño del método es robusto frente a errores de calibración.

Tabla 4: Caracterización del *plateau*. Caída relativa de $AUC_{0.1}$ respecto del máximo y número de combinaciones (sobre 120) dentro de cada tolerancia absoluta.

Especie	$AUC_{0.1}^{\max}$	caída (%) al k -ésimo			n dentro de		
		$k=5$	$k=10$	$k=20$	0,001	0,005	0,01
<i>T. cruzi</i>	0,849	0,43	0,82	1,09	2	5	16
<i>T. brucei</i>	0,789	0,24	0,48	1,14	3	10	13
<i>L. major</i>	0,743	0,23	0,30	1,55	2	12	17
<i>P. falciparum</i>	0,736	0,65	1,40	1,90	2	4	8
<i>A. thaliana</i>	0,683	0,21	0,52	0,83	1	8	35
<i>C. elegans</i>	0,664	0,80	1,12	1,54	1	3	7
<i>D. discoideum</i>	0,652	1,12	1,59	2,14	2	2	4
<i>C. albicans</i>	0,645	0,14	0,29	1,36	2	13	18
<i>O. sativa</i>	0,644	0,18	0,24	0,46	1	21	29
<i>D. melanogaster</i>	0,614	0,82	1,08	1,56	1	3	7
<i>M. musculus</i>	0,611	0,10	0,16	0,34	4	24	44
<i>H. sapiens</i>	0,594	1,05	1,82	2,14	1	2	4
<i>S. aureus</i>	0,591	0,17	0,79	1,60	3	8	11
<i>E. coli</i>	0,588	0,31	0,47	0,78	2	10	20
<i>S. cerevisiae</i>	0,581	0,06	0,10	0,15	9	27	48
<i>M. tuberculosis</i>	0,581	0,15	0,26	0,95	3	14	20




Figura 11: Caída relativa de $AUC_{0.1}$ al descender en el ranking de combinaciones de parámetros. La planitud de las curvas indica que la elección del vector óptimo exacto es poco crítica.

Qué parámetro importa realmente. El análisis de enriquecimiento de valores en el $top-k$ de cada especie (Tabla 5, Figura 13) identifica un único parámetro fuertemente seleccionado: $\beta = 1$ aparece en el 61,3 % de las mejores combinaciones frente al 25 % esperado por azar, un enriquecimiento de 2,45. Los demás valores de β están claramente sub-representados, y en particular $\beta = 0$ — la red G'_r sin corrección por tamaño de categoría — tiene enriquecimiento 0,25. Es una confirmación cuantitativa, sobre 16 especies independientes, de que la corrección por tamaño de categoría es un ingrediente necesario del modelo y no un refinamiento opcional.

En contraste, α es casi indistinguible del azar (enriquecimientos entre 0,81 y 1,31), lo que sugiere que la ponderación por relevancia de Fisher aporta poco una vez que se corrige por tamaño. Para λ , los valores intermedios 0,5 y 1,0 están moderadamente enriquecidos (1,54 y 1,46) mientras que $\lambda = 0$ está penalizado (0,60), y el modo híbrido queda por debajo de lo esperado (0,80): la flexibilidad adicional del híbrido no se traduce en mejor desempeño.

Tabla 5: Consistencia de la selección de parámetros entre especies. Enriquecimiento = frecuencia en el $top-k$ / frecuencia en la grilla.

Parámetro	Valor	Frec. $top-k$	Frec. grilla	Enriquecimiento
β	1,0	0,613	0,250	2,45
β	1,5	0,225	0,250	0,90
β	0,5	0,100	0,250	0,40
β	0,0	0,063	0,250	0,25
λ	0,5	0,256	0,167	1,54
λ	1,0	0,244	0,167	1,46
λ	híbrido	0,400	0,500	0,80
λ	0,0	0,100	0,167	0,60
α	0,3	0,263	0,200	1,31
α	0,0	0,244	0,200	1,22
α	1,2	0,169	0,200	0,84
α	0,9	0,163	0,200	0,81
α	0,6	0,163	0,200	0,81
γ	0,8	0,750	0,667	1,13
γ	1,0	0,131	0,167	0,79
γ	1,2	0,119	0,167	0,71




Figura 12: Efecto marginal de cada parámetro sobre $AUC_{0.1}$. El panel de β compara directamente la red sin corrección de tamaño ($\beta = 0$, equivalente a G'_r) contra las variantes corregidas ($\beta > 0$, G'_{rk}).




Figura 13: Enriquecimiento de cada valor de parámetro en el $top-k$ de las 16 especies respecto de su frecuencia en la grilla. Sólo $\beta = 1$ muestra una selección fuerte y consistente.

¿Se puede usar un único vector global? La correlación de Spearman entre los perfiles de $AUC_{0.1}$ sobre la grilla (Figura 14) es alta entre especies filogenéticamente afines — $\rho = 0,99$ entre *C. elegans* y *T. cruzi*, $\rho = 0,96$ entre *L. major* y *T. brucei*, $\rho = 0,96$ entre *A. thaliana* y *M. musculus* — pero hay dos excepciones marcadas. *S. cerevisiae* correlaciona *negativamente* con casi todo el panel ($\rho = -0,71$ frente a *L. major*, $\rho = -0,65$ frente a *T. brucei*), y *S. aureus* es esencialmente ortogonal ($|\rho| < 0,4$ frente a la mayoría). Ambas especies son también las que eligen vectores óptimos atípicos (Tabla 3): *S. cerevisiae* es la única con $\beta = 0$ y $\lambda = 0$, y *S. aureus* la única con $\beta = 0,5$ y $\alpha = 0,3$ simultáneamente.

La conclusión práctica es matizada: dado el *plateau* documentado más arriba, adoptar un vector global del tipo ($\alpha \approx 0,3$; $\beta = 1$; $\lambda = 0,5-1$; $\gamma = 0,8$) costaría muy poco desempeño en la mayoría de las especies, y en particular en los cuatro protozoos de mayor interés. Pero conviene mantener la calibración por especie para los casos atípicos, donde el perfil de la grilla es genuinamente distinto.




Figura 14: Correlación de Spearman entre los perfiles de $AUC_{0.1}$ sobre la grilla de parámetros. La estructura de bloques sigue a la filogenia; *S. cerevisiae* y *S. aureus* se apartan del patrón general.

3.7 Desorfanización: calibración con pseudo-huérfanas

El problema inverso al de priorización es el siguiente: dado un compuesto activo sobre un organismo pero sin blanco proteico conocido, ¿qué proteínas de ese organismo son candidatas? El procedimiento consiste en usar los blancos conocidos de los vecinos químicos del compuesto huérfano como semilla y propagar; las proteínas mejor rankeadas son las sugerencias.

Para calibrar el procedimiento se construyó un experimento de *pseudo-huérfanas*: se toman compuestos con blanco conocido, se oculta esa información, se corre el método, y se mide en qué posición del ranking aparece el blanco verdadero. La métrica es el rango fraccional $f_{\text{rank}} \in [0, 1]$, donde $f_{\text{rank}} = 0$ indica recuperación perfecta y $f_{\text{rank}} = 0,5$ corresponde al azar. Se muestrearon hasta 1000 compuestos por especie ($n = 7782$ pares en total), con semilla aleatoria fija.


La cobertura de la semilla lo determina todo. El resultado agregado es aparentemente pobre: sólo el 2,63 % de los pares alcanza $f_{\text{rank}} \leq 0,1$. Pero ese número promedia situaciones incomparables. Al desagregar por el tipo de semilla disponible (Figura 15, Tabla 6) el panorama cambia por completo:

- **Semilla nula** ($n = 6470$, el 83,1 % de los casos): el compuesto no tiene ningún vecino químico con blanco conocido. No hay nada que propagar y la recuperación es, por construcción, del 0 %.
- **Semilla no informativa** ($n = 1105$): hay vecinos con blancos, pero ninguno aporta señal sobre el blanco verdadero. Recuperación: 0 %.
- **Semilla informativa** ($n = 207$): recuperación del **99,0 %** con $f_{\text{rank}} \leq 0,1$.


Esta descomposición es central para interpretar el método: no es un predictor con 2,6 % de acierto, sino un predictor casi perfecto que sólo es aplicable al 2,7 % de los casos. El cuello de botella no es el algoritmo de propagación sino la cobertura de la capa química — lo que concuerda con la fragmentación documentada en la Figura 3 y con la pobreza de la conectividad química cruzada de la Figura 4b. Cualquier mejora sustancial del rendimiento global pasa por ampliar la evidencia química, no por refinar el propagador.

Tabla 6: Recuperación del blanco verdadero en el experimento de pseudo-huérfanas, corte $f_{\text{rank}} \leq 0,1$.


Partición	Valor	n	% recuperadas	% sin semilla
Total	todas	7782	2,63	83,14
Semilla	informativa	207	99,03	0,00
Semilla	no informativa	1105	0,00	0,00
Semilla	nula	6470	0,00	100,00
Clase	directa	124	100,00	0,00
Clase	indirecta	1188	6,82	0,00
Clase	sin semilla	6470	0,00	100,00
Grupo	0	2577	0,81	90,07
Grupo	1	1494	1,47	87,82
Grupo	2	2066	4,21	76,23
Grupo	3	1645	4,56	76,72




(a) Grupos por especie.



(b) f_{rank} por grupo.



(c) Tipo de semilla por especie.




(d) Recuperación según semilla.

Figura 15: Experimento de pseudo-huérfanos. La recuperación del blanco verdadero está determinada casi por completo por la disponibilidad de una semilla informativa (d), no por la especie ni por el grupo.


La desagregación por especie confirma el mismo patrón: la fracción de casos sin semilla va del 67,4 % en *O. sativa* al 89,8 % en *M. tuberculosis*, y la tasa de recuperación sigue inversamente a esa fracción (13,95 % en *O. sativa*, 1,90 % en *M. tuberculosis*). *P. falciparum*, con 81,8 % de casos sin semilla, recupera el 0,80 %.

Inferencia directa e indirecta. Entre los casos con semilla, conviene distinguir dos regímenes (Figura 16). En la inferencia *directa* ($n = 124$) el blanco verdadero está entre los blancos de la semilla; la recuperación es del 100 % y las medianas de rango son muy bajas (por ejemplo, $r_G = 16$ en *M. tuberculosis*, $r_G = 20,5$ en *E. coli*, $r_G = 9,5$ en *A. thaliana*). En la inferencia *indirecta* ($n = 1188$) el blanco debe alcanzarse propagando a través de categorías funcionales; la recuperación cae al 6,82 % y las medianas de r_G se van al orden de $1,85 \times 10^5$, es decir, indistinguibles del azar.

Este contraste acota honestamente el alcance del método: la propagación funcional recupera el blanco cuando éste ya está en el entorno inmediato de la semilla, pero rara vez lo alcanza por transitividad pura.



(a) Distribución de r_G .



(b) Directa vs. indirecta.

Figura 16: Regímenes de inferencia. La inferencia directa concentra los rangos globales bajos; la indirecta produce una distribución compatible con el azar.

3.8 Un umbral de decisión: r_G^*


Los resultados anteriores plantean una pregunta operativa: dada una sugerencia con rango global r_G , ¿a partir de qué valor deja de ser confiable? Para responderla se construyó la curva de recuperación acumulada $\rho(\ell)$: el número de blancos verdaderos recuperados dentro de las primeras ℓ posiciones del ranking global, hasta $\ell_{\max} = 1000$ (Figura 17).

La curva crece rápidamente al principio — 5 recuperaciones en la primera posición, 24 en las primeras cinco, 47 en las primeras diez — y luego se aplanan. La tasa incremental suavizada $\lambda(\ell)$ converge a un valor asintótico $\lambda_\infty = 0,0855$ con desviación $\sigma = 0,1263$, estimados sobre la cola $\ell \geq 500$. Definimos entonces el umbral r_G^* como el primer ℓ a partir del cual la tasa incremental cae por debajo de $\lambda_\infty + k\sigma$ con $k = 3$, es decir, el punto donde el aporte de seguir bajando en el ranking deja de ser estadísticamente distinguible del ruido de fondo. El umbral resultante es


$$r_G^* = 54 \quad (\text{umbral de tasa} = 0,4643, k_\sigma = 3). \quad (3)$$

La interpretación operativa es directa: una sugerencia con $r_G \leq 54$ está en la región donde el método demostrablemente concentra sus aciertos; por encima de ese valor la sugerencia no se distingue del azar y no debería reportarse.

Este criterio es un aporte propio de esta realización: convierte un método que produce un ranking completo del proteoma — y que por lo tanto siempre devuelve *algo* — en un procedimiento con una regla de abstención explícita.



(a) Curva de recuperación y r_G^* .



(b) Distribución de r_{SS} .

Figura 17: Derivación del umbral de decisión. (a) La tasa incremental de recuperación cae por debajo del ruido de fondo en $r_G^* = 54$. (b) El rango dentro del subespacio de la semilla (r_{SS}) confirma la concentración de aciertos en las primeras posiciones: el 5,3 % de los casos acierta en la posición 1 y el 11,2 % dentro de las diez primeras.

3.9 Aplicación: compuestos antipalúdicos huérfanos

Como caso de uso se aplicó el procedimiento calibrado a compuestos con actividad fenotípica documentada contra *P. falciparum* pero sin blanco proteico asignado, usando la configuración óptima de la especie $(\alpha, \beta, \lambda, \gamma) = (1,2; 1,0; 1,0; 0,8)$ y el umbral $r_G^* = 54$.

El embudo de selección (Tabla 7, Figura 18) parte de 233 compuestos fenotípicamente activos. De ellos, 32 carecen de blanco proteico conocido — son los huérfanos genuinos — y de esos 32, sólo 12 (37,5 %) son tratables por el método, es decir, tienen al menos un vecino químico con blanco conocido que permita construir una semilla. Los 20 restantes están aislados en el espacio químico y el método no tiene nada que decir sobre ellos.

Tabla 7: Embudo de selección para *P. falciparum*.

Paso	n	% del anterior
1 — Fenotípicamente activos	233	—
2 — Sin blanco proteico (huérfanos)	32	13,7
3 — Tratables por el método	12	37,5





Figura 18: Embudo de selección de compuestos antipalúdicos huérfanos. La caída principal ocurre en el paso 3, por falta de vecindad química informativa.


Tras aplicar el umbral $r_G^* = 54$ sobre las sugerencias de los 12 compuestos tratables, sobreviven dos predicciones, ambas provenientes del compuesto `drug_id` 560020 (Tabla 8): las proteínas Q8IK11 y Q8I242, con $r_G = 15,5$ — muy por debajo del umbral — y puntaje idéntico, lo que indica que son indistinguibles para el modelo y que la sugerencia debe leerse como un par funcional y no como dos predicciones independientes.

Tabla 8: Sugerencias de blanco que superan el criterio $r_G \leq r_G^* = 54$ para *P. falciparum*.

Compuesto	Blanco sugerido	NDS	r_G
560020	Q8IK11	0,01148	15,5
560020	Q8I242	0,01148	15,5



(a) r_G de las sugerencias y umbral.



(b) Familias funcionales.

Figura 19: Sugerencias para *P. falciparum*. (a) Sólo dos sugerencias caen por debajo del umbral $r_G^* = 54$; el resto se descarta. (b) Familias funcionales involucradas en las sugerencias generadas.

El rendimiento numérico es deliberadamente austero: de 233 compuestos de partida se llega a dos sugerencias. Pero ése es el punto del umbral. Sin él, el método habría producido un ranking completo de las 5495 proteínas de *P. falciparum* para cada uno de los 12 compuestos tratables, y la elección de un corte habría quedado librada al criterio del usuario.

4 Discusión

Reproducibilidad. La reimplementación reproduce la corrida de referencia con coincidencia exacta del vector de parámetros óptimo en las 16 especies. Los valores de $AUC_{0,1}$ obtenidos son

consistentes con los reportados en el trabajo original [1] para las especies comparables, lo que valida el pipeline como base para las extensiones.

La estructura de la red condiciona el método más que sus parámetros. Tres resultados independientes apuntan en la misma dirección. Primero, la matriz de conectividad química cruzada (Sección 3.3) muestra que fuera de *H. sapiens* casi no hay evidencia compartida entre organismos. Segundo, el 83,1 % de las pseudo-huérfanas no tiene ninguna semilla disponible (Sección 3.7). Tercero, en el caso de *P. falciparum*, el 62,5 % de los huérfanos genuinos se descarta por falta de vecindad química. En los tres casos el factor limitante es la cobertura de la capa química, no la calidad del propagador. La consecuencia para trabajo futuro es clara: incorporar más fuentes de similitud química o de bioactividad tendría un impacto mucho mayor que refinar la parametrización.

El modelo es robusto y esencialmente unidimensional en sus parámetros. El análisis de *plateau* muestra mesetas amplias — hasta 48 de 120 combinaciones dentro de 0,01 del máximo — y el análisis de consistencia identifica a $\beta = 1$ como el único parámetro con selección fuerte y reproducible entre especies ($2,45\times$ sobre el azar). En particular, el modo híbrido de λ , que agrega un parámetro adicional (γ), está sub-representado en los óptimos ($0,80\times$): su flexibilidad no se traduce en desempeño. Esto sugiere que una versión simplificada del modelo, con $\beta = 1$ fijo, λ fijo en 0,5 o 1 y α eliminado, retendría casi todo el desempeño con la mitad de los parámetros.

Alcance honesto de las predicciones. La distinción entre inferencia directa e indirecta acota lo que el método puede hacer: recupera el blanco casi siempre cuando éste está en el entorno inmediato de la semilla (100 %), y rara vez cuando debe alcanzarse por propagación transitiva (6,8 %). El umbral $r_G^* = 54$ formaliza esa limitación como una regla de abstención. Nos parece preferible reportar dos sugerencias defendibles que un ranking completo sin criterio de corte.

Limitaciones. El experimento de pseudo-huérfanas usa un único muestreo ($n = 1000$ por especie, semilla 123457); no se estimó la varianza entre muestreos. El umbral r_G^* se derivó agregando todas las especies, con lo que asume que la escala de r_G es comparable entre proteomas de tamaño muy distinto (2187 a 27 425 proteínas); una versión normalizada por tamaño de proteoma sería más rigurosa. El valor $k_\sigma = 3$ es una elección convencional y no está optimizado. Finalmente, las dos sugerencias para *P. falciparum* son predicciones computacionales que requieren validación experimental.

5 Conclusiones

1. Se reprodujo íntegramente el pipeline de priorización de blancos basado en red multicapa sobre una instantánea actualizada de la base, con coincidencia exacta de los parámetros óptimos en las 16 especies respecto de la implementación de referencia.
2. La caracterización de la red revela una asimetría fundamental: la capa de afiliaciones funcionales conecta densamente a todas las especies, mientras que la evidencia química compartida es escasa y está concentrada en *H. sapiens*. Esto justifica estructuralmente el diseño del propagador.
3. Se identificó y corrigió un sesgo por compuestos promiscuos de bajo peso molecular: 30 compuestos (0,015 %) concentraban el 11,98 % de las aristas de bioactividad.
4. El desempeño alcanza $AUC_{0.1}$ entre 0,58 y 0,85, con los protozoos patógenos — objetivo primario del método — en las primeras posiciones.

5. El óptimo del barrido es una meseta amplia y no un pico: $\beta = 1$ es el único parámetro con selección fuerte y consistente entre especies ($2,45\times$ sobre el azar), lo que abre la puerta a una versión simplificada del modelo.
6. En desorfanización, el método es un predictor casi perfecto (99,0 %) sobre el 2,7 % de los casos que tienen semilla informativa; el cuello de botella es la cobertura química.
7. Se derivó un umbral de decisión operativo, $r_G^* = 54$, que define cuándo una sugerencia es distinguible del azar, y se lo aplicó a compuestos antipalúdicos huérfanos, obteniendo dos sugerencias de blanco con $r_G = 15,5$ a partir de 233 compuestos de partida.

Referencias

- [1] Ariel J. Berenstein, María Paula Magariños, Ariel Chernomoretz, and Fernán Agüero. A multilayer network approach for guiding drug repositioning in neglected diseases. *PLoS Neglected Tropical Diseases*, 10(1):e0004300, 2016. doi: 10.1371/journal.pntd.0004300.
- [2] Lionel Urán Landaburu, Ariel J. Berenstein, Santiago Videla, Parag Maru, Dhanasekaran Shanmugam, Ariel Chernomoretz, and Fernán Agüero. TDR targets 6: driving drug discovery for human pathogens through intensive chemogenomic data integration. *Nucleic Acids Research*, 48(D1):D992–D1005, 2020. doi: 10.1093/nar/gkz999.
- [3] Matthias Blum, Hsin-Yu Chang, Sara Chuguransky, et al. The InterPro protein families and domains database: 20 years on. *Nucleic Acids Research*, 49(D1):D344–D354, 2021. doi: 10.1093/nar/gkaa977.
- [4] Li Li, Christian J. Stoeckert, and David S. Roos. OrthoMCL: Identification of ortholog groups for eukaryotic genomes. *Genome Research*, 13(9):2178–2189, 2003. doi: 10.1101/gr.1224503.
- [5] David Rogers and Mathew Hahn. Extended-connectivity fingerprints. *Journal of Chemical Information and Modeling*, 50(5):742–754, 2010. doi: 10.1021/ci100050t.
- [6] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.
- [7] Donna Katzman McClish. Analyzing a portion of the ROC curve. *Medical Decision Making*, 9(3):190–195, 1989. doi: 10.1177/0272989X8900900307.